

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ
АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ)»
(НИУ МАИ)

УДК: индекс УДК TODO

Рег. №: регистрационный номер НИР TODO

Рег. № ИКРБС: регистрационный номер отчета TODO

СОГЛАСОВАНО

Должность, сокращ. наимен.
орг TODO

Фамилия И.О. TODO
« ____ » _____ 2026 г.

УТВЕРЖДАЮ

Должность, сокращ. наимен.
орг TODO

Фамилия И.О. TODO
« ____ » _____ 2026 г.

ОТЧЁТ

О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

по теме:

РЕАЛИЗАЦИЯ ГЛОБАЛЬНОГО ВТОРИЧНОГО ИНДЕКСА И
СРАВНИТЕЛЬНЫЙ АНАЛИЗ ЕГО ПРОИЗВОДИТЕЛЬНОСТИ С
ЛОКАЛЬНЫМИ ИНДЕКСАМИ В РАСПРЕДЕЛЕННОЙ СУБД PICODATA

Руководитель НИР,
Должность TODO

подпись, дата

Романенков А.М.

Исполнитель НИР,
Студент

подпись, дата

В.М. Клименко

Москва 2026

РЕФЕРАТ

Отчёт 27 с., 1 рис., 1 ист.

TODO ОТ 5 ДО 15 СЛОВ/СЛОВСОЧЕТАНИЙ

Построение и использование вторичного глобального индекса в распределенной СУБД Picodata, сравнение с локальными индексами в контексте различных моделей доступа к данным.

СОДЕРЖАНИЕ

Термины и определения	5
Перечень сокращений и обозначений	6
Введение	7
1 Вербальное описание области, направления работы, места и роли продукта, план работы	9
1.1 Место и роль результата главы	9
1.2 Описание предметной области	9
1.3 Направления работы	10
1.4 Место и роль продукта НИР	11
1.5 План выполнения работы	11
1.6 Характеристика полученного артефакта	12
1.7 Оценка качества артефакта	13
1.7.1 Полнота	13
1.7.2 Непротиворечивость	14
1.7.3 Прослеживаемость	14
1.7.4 Пригодность для последующего проектирования	14
2 Инфологическая схема предметной области продукта	15
2.1 Место и роль результата главы	15
2.2 Изложение артефакта	15
2.2.1 Описание условных обозначений	16
2.2.2 Описание сущностей	17
2.2.3 Описание связей	19
2.3 Характеристика полученного результата	20
2.4 Оценка качества артефакта	20
3 Модель функционирования устройства, в которую внедряется продукт	22

4	Модель процессов функционирования продукта и его составных частей	23
5	Описание архитектуры программного обеспечения	24
6	Программа и методики испытаний ПО в составе основных сведений, позволяющих показать пути проверки достижения заданного качества программного обеспечения	25
	Заключение	26
	Список использованных источников	27

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчете о НИР применяют следующие термины с соответствующими определениями.

Инстанс — один запущенный процесс базы данных

Мастер — инстанс, принимающий запросы на запись и чтение

Реплика — инстанс, принимающий запросы только на чтение

Репликасет — набор инстансов, хранящих одинаковую часть данных, в котором один является мастером, а остальные являются репликами, принимающими и применяющими поток изменений от мастера

Шардирование — разбиение данных по репликасетам

Бакет — единица балансировки. Виртуальная сущность, к которой однозначно привязаны данные

Ключ шардирования — атрибуты записи, по которым происходит определение ее бакета

Таблица — совокупность связанных данных, хранящихся в структурированном виде

Шардированная таблица — таблица, данные которой распределены между репликасетами по бакетам

Кластер — набор репликасетов, предоставляющий доступ к единой СУБД

Плагин — единица программного обеспечения, представленная динамической библиотекой, расширяющая функционал инстанса

Драйвер — программное обеспечение, предоставляющее интерфейс взаимодействия с кластером

Персистентность — свойство данных сохраняться на диск, чтобы быть доступными после перезапуска инстанса

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчете о НИР применяют следующие сокращения и обозначения.

СУБД — система управления базами данных

ПО — программное обеспечение

ГВИ — глобальный вторичный индекс. Вторичный индекс, шардированный вне зависимости от ключа шардирования индексируемой таблицы

ЛВИ — локальный вторичный индекс. Вторичный индекс, шардированный как и ключ шардирования индексируемой таблицы

ER-диаграмма — entity-relationship (сущность-связь) диаграмма, выполненная в нотации Чена

Read-only нагрузка — модель обращения к данным, при которой происходит только чтение данных, без их изменения

Read-write нагрузка — модель обращения к данным, при которой происходят чтение и изменение данных

ВВЕДЕНИЕ

Главная особенность распределенных СУБД — разделение данных одной таблицы между несколькими инстансами. Это позволяет совершать поиск с фильтрацией по ключу шардирования с высокой эффективностью: составитель плана исполнения запроса отправит запрос только на репликaset, хранящий запись с ключом шардирования из фильтра, чтобы избежать опроса всего кластера.

Однако при использовании локальных вторичных индексов, поиск по ним в больших кластерах значительно замедляется из-за необходимости произвести поиск в каждом репликasetе. На сегодняшний день для СУБД Picodata решения этой проблемы нет.

Объект этого исследования — поиск в распределенных СУБД. Предмет — глобальный вторичный индекс в распределенной СУБД Picodata. Цель данной НИР — разработать ПО, добавляющее возможность использования глобального вторичного индекса в СУБД Picodata в виде плагина, произвести сравнение производительности с локальными вторичными индексами при различных моделях доступа к данным и составить список рекомендаций по использованию конкретного типа вторичного индекса.

Предполагается, что использование глобальных индексов может ускорять поиск по вторичным индексам при определенных нагрузках.

Для достижения поставленной цели определены следующие задачи:

- 1) изучить существующие реализации глобальных вторичных индексов;
- 2) спроектировать архитектуру плагина для использования глобальных вторичных индексов;
- 3) реализовать вышеупомянутый плагин;
- 4) реализовать драйвер, имеющий возможность использовать интерфейс плагина для построения глобального вторичного индекса и поиска в нем;
- 5) произвести нагрузочное тестирование и сравнить эффективность поиска через глобальный и локальный вторичные индексы при разных моделях доступа к данным.

Настоящая НИР содержит результаты проектирования и реализации ПО, описания методов нагрузочного тестирования и составление выводов по ним.

1 Вербальное описание области, направления работы, места и роли продукта, план работы

1.1 Место и роль результата главы

Результатом данной главы является формализованное вербальное описание предметной области, направления научно-исследовательской работы и места разрабатываемого программного продукта в инфраструктуре распределенной системы управления базами данных.

Описание выполняет следующие функции:

- определяет границы исследуемой системы;
- фиксирует проблемную ситуацию;
- формирует контекст проектирования архитектуры;
- задает основу для построения инфологической модели (глава 2);
- формирует исходные положения для выбора архитектурных решений (глава 5).

Дополнительным назначением результата является подготовка базы для сравнительного анализа локальных и глобальных индексов.

1.2 Описание предметной области

Предметной областью работы является организация эффективного поиска данных в распределенных системах управления базами данных.

Рассматривается распределенная СУБД Picodata, в которой данные распределяются по нескольким узлам кластера, объединенным в репликасеты.

В распределенных СУБД вторичные индексы могут быть:

- локальными — хранящимися на каждом узле отдельно;
- глобальными — представляющими единое распределенное индексное пространство.

В текущей реализации Picodata поддерживаются только локальные вторичные индексы, что может приводить к:

- паразитным сетевым переходам;

- избыточной нагрузке на CPU;
- неоптимальному распределению поисковых операций.

Проблема особенно выражена при высокой кардинальности индексируемого атрибута (количество уникальных значений близко к числу записей).

1.3 Направления работы

Сейчас в Picodata нет функционала глобального вторичного индекса, поэтому при определенных нагрузках, поиск по вторичным индексам может происходить с лишними затратами — паразитными переходами по сети и использованием времени центрального процессора на поиск несуществующей в индексе записи. Например, такая ситуация может возникнуть, если кардинальность индексируемого атрибута близка к количеству записей в таблице.

Данная НИР нацелена на изменение этой ситуации посредством предоставления функционала работы с глобальными индексами администраторам СУБД Picodata.

У этой работы можно выделить три направления:

- 1) разработка ПО, реализующего функционал глобального индекса в виде плагина к распределенной СУБД Picodata;
- 2) произведение сравнительного анализа производительности глобальных и локальных индексов;
- 3) создание практических рекомендаций по выбору типа индексов.

Для создания рекомендаций по использованию глобальных индексов будет проведено нагрузочное тестирование с различными топологиями кластера и моделями доступа к данным. Ниже приведен список параметров нагрузки на кластер базы данных:

- режим нагрузки: read-only или read-write;
- кардинальность индексируемого атрибута;
- количество репликасетов;
- персистентность индекса;
- топология кластера.

1.4 Место и роль продукта НИР

Основным продуктом НИР является плагин к СУБД Picodata, добавляющий функционал глобальных индексов и интерфейс работы с ними.

Функциональные возможности плагина:

- создание глобального индекса;
- обновление индекса при изменении данных;
- удаление индекса;
- выполнение поисковых запросов с использованием глобального индекса.

Целевые пользователи:

- администраторы СУБД Picodata;
- разработчики распределенных приложений.

Побочными продуктами НИР будут выступать:

- 1) драйвер поиска, с доступом к плагину;
- 2) методические рекомендации по выбору типа индекса;
- 3) результаты нагрузочного тестирования.

1.5 План выполнения работы

Работа выполняется в следующей последовательности:

- 1) анализ архитектуры Picodata;
- 2) проектирование модели глобального индекса;
- 3) разработка прототипа плагина;
- 4) реализация механизмов обновления и поиска;
- 5) разработка методики нагрузочного тестирования;
- 6) проведение тестов;
- 7) сравнительный анализ;
- 8) формирование рекомендаций.

1.6 Характеристика полученного артефакта

Полученное описание является достаточно полным для понимания контекста работы, охватывает ключевые аспекты: проблему отсутствия глобальных индексов в Picodata, цели работы, ожидаемые результаты и границы создаваемого плагина. Описание не содержит внутренних противоречий и согласовано с задачами ВКР

Характеристика полученного артефакта

Полученное вербальное описание представляет собой формализованное текстовое представление контекста работы. Оно охватывает следующие аспекты:

- проблематика: зафиксирована текущая ситуация (отсутствие глобальных индексов в Picodata) и ее негативные последствия;
- целевая аудитория: явно указаны основные пользователи разрабатываемого плагина и рекомендаций;
- границы системы: определено, что разрабатывается именно плагин, а не модификация ядра СУБД; описаны функции плагина;
- объект исследования: выделены параметры нагрузки, влияющие на производительность индексов (кардинальность, режим доступа, топология кластера), что формирует базу для дальнейшего тестирования;
- план работы: перечислены этапы, что обеспечивает понимание последовательности действий и конечных целей.

Полученный результат представляет собой текстовый аналитический артефакт — формализованное вербальное описание предметной области и направления научно-исследовательской работы.

Артефакт обладает следующими характеристиками:

- тип артефакта — концептуально-аналитический;
- уровень абстракции — системный (без детализации внутренних алгоритмов);
- область охвата — распределенные СУБД, механизмы вторичного индексирования, особенности архитектуры СУБД Picodata;

- функциональная направленность — формирование требований к разработке глобального вторичного индекса;
- границы системы — плагин индексирования рассматривается как расширение существующей СУБД, без модификации ее базового ядра;
- связность с последующими главами:
 - задает основу для инфологической схемы (глава 2);
 - определяет элементы модели функционирования (глава 3);
 - формирует требования к архитектуре (глава 5);
 - определяет параметры испытаний (глава 7).

Описание является достаточно полным для понимания контекста работы, охватывает ключевые аспекты: проблему отсутствия глобальных индексов, цели разработки, ожидаемые результаты и границы создаваемого плагина.

Артефакт не содержит внутренних логических противоречий и согласован с темой ВКР.

1.7 Оценка качества артефакта

Оценка качества полученного вербального описания проводится по следующим критериям:

1.7.1 Полнота

Описание охватывает:

- предметную область;
- проблемную ситуацию;
- направления исследования;
- параметры сравнительного анализа;
- место продукта в инфраструктуре.

Таким образом, критерий полноты выполняется.

1.7.2 Непротиворечивость

Формулировки не содержат логических конфликтов.

1.7.3 Прослеживаемость

Цели и направления работы напрямую вытекают из выявленной проблемы. Каждый заявленный этап плана работы связан с достижением измеримого результата.

1.7.4 Пригодность для последующего проектирования

Описание создает основу для:

- построения инфологической модели;
- формализации процессов функционирования;
- разработки архитектуры;
- определения метрик испытаний.

2 Инфологическая схема предметной области продукта

2.1 Место и роль результата главы

Результатом данной главы является инфологическая (концептуальная) схема предметной области, которая отражает основные сущности, их атрибуты и связи, существующие в контексте работы с глобальными и локальными вторичными индексами в распределенной СУБД Picodata. Схема служит промежуточным звеном между вербальным описанием (глава 1) и последующим проектированием архитектуры программного продукта (глава 5). Она позволяет:

- формализовать знания о предметной области;
- выявить ключевые объекты, участвующие в процессах индексирования и поиска;
- установить ограничения и правила целостности;
- создать основу для разработки физической модели данных и структур плагина.

2.2 Изложение артефакта

Инфологическая схема предметной области представлена в виде диаграммы «сущность-связь» на рисунке 1.




Рисунок 1 – ER-диаграмма

2.2.1 Описание условных обозначений

Диаграмма выполнена в нотации Чена для моделирования «сущность-связь». Используемые обозначения:

- прямоугольник — сущность;
- ромб — связь;
- овал — атрибут сущности;
- линии — соединения, показывающие участие сущности в связи.
- 1:1 — связь «один к одному».
- 1:N — связь «один ко многим».

Нотация описана в работе Р. Р. Chen «The Entity-Relationship Model — Toward a Unified View of Data» (1976) [1]

2.2.2 Описание сущностей

В модели выделены следующие сущности и их атрибуты:

- пользователь — лицо, инициирующее запросы к СУБД;
- драйвер — ПО, предоставляющее интерфейс взаимодействия с СУБД;
- база данных — кластер СУБД Picodata. Атрибуты:
 - версия — идентификатор варианта СУБД на определенном этапе развития;
- репликасет — набор инстансов, хранящих одинаковую часть данных, в котором один является мастером, а остальные являются репликами, принимающими и применяющими поток изменений от мастера. Атрибуты:
 - распределение бакетов — список бакетов, принадлежащих данному репликасету;
- инстанс — один запущенный процесс Picodata. Атрибуты:
 - является мастером — булево значение, показывающее роль в репликасете: мастер или реплика;
- движок хранения — тип используемого механизма хранения данных;
- таблица — совокупность связанных данных, хранящихся в структурированном виде. Атрибуты:
 - название — идентификатор таблицы;
 - названия атрибутов — идентификаторы полей записей;

- данные — набор записей;
- первичный ключ — список идентификаторов полей, по которым происходит шардирование;
- плагин — единица программного обеспечения, расширяющая функционал инстанса;
- таблица ГВИ — таблица, которая представляет из себя глобальный вторичный индекс. Атрибуты:
 - название — идентификатор таблицы;
- запись в таблице ГВИ — конкретное значение вхождения в индекс. Атрибуты:
 - значение индексируемого атрибута;
 - метаданные для обновления — значение последнего времени обновления записи;
 - первичный ключ записи индексируемой таблицы — значение полей, по которым происходит шардирование индексируемой таблицы;
- таблица метаданных ГВИ — вспомогательная таблица с информацией о глобальных вторичных индексах;
- запись в таблице метаданных ГВИ — информация о построенном глобальном вторичном индексе. Атрибуты:
 - название индексируемой таблицы;
 - название индексируемого атрибута;
 - название таблицы ГВИ;
- таблица статуса построения ГВИ — вспомогательная таблица с информацией о статусе построения глобальных вторичных индексов. Атрибуты:
 - название таблицы ГВИ;
 - название индексируемой таблицы;
 - название индексируемого атрибута;
- запись в таблице статуса построения ГВИ — информация о статусе построения глобального вторичного индекса. Атрибуты:
 - счетчик индексирования бакета — монотонно-возрастающий счетчик для верного обновления глобального вторичного индекса;

- бакет записей — номер бакета, которому соответствует счетчик.

2.2.3 Описание связей

- **пользователь** → **драйвер**: пользователь использует драйвер (1:1);
- **драйвер** → **база данных**: драйвер посылает запросы в базу данных (1:1);
- **база данных** → **репликасет**: база данных состоит из репликасетов (1:N);
- **репликасет** → **инстанс**: репликасетов состоит из инстансов (1:N);
- **инстанс** → **движок хранения**: инстанс имеет несколько движков хранения (1:N);
- **движок хранения** → **таблица**: движок хранения содержит множество таблиц (1:N);
- **инстанс** → **плагин**: инстанс запускает плагин построения ГВИ (1:1);
- **плагин** → **движок хранения**: плагин использует движки хранения для создания таблиц (1:N);
- **плагин** → **таблица ГВИ**: плагин строит множество глобальных вторичных индексов (1:N);
- **таблица ГВИ** → **запись в таблице ГВИ**: таблица ГВИ состоит из множества записей (1:N);
- **плагин** → **таблица метаданных ГВИ**: плагин строит множество глобальных вторичных индексов (1:N);
- **таблица метаданных ГВИ** → **запись в таблице метаданных ГВИ**: таблица метаданных ГВИ состоит из множества записей (1:N);
- **плагин** → **таблица статуса построения ГВИ**: плагин строит множество глобальных вторичных индексов (1:N);
- **таблица статуса построения ГВИ** → **запись в таблице статуса построения ГВИ**: таблица статуса построения ГВИ состоит из множества записей (1:N).

2.3 Характеристика полученного результата

Разработанная инфологическая схема предметной области представляет собой концептуальную модель, отражающую основные сущности, их атрибуты и связи, необходимые для реализации и использования глобальных вторичных индексов в распределенной СУБД Picodata. Модель охватывает следующие ключевые уровни:

- пользовательский уровень — сущности «пользователь» и «драйвер», описывающие инициацию запросов к СУБД;
- инфраструктурный уровень — сущности «база данных», «репликасет», «инстанс», «движок хранения», «плагин», задающие топологию кластера и среду исполнения;
- уровень хранения данных — сущности «таблица» (пользовательские данные) и связанные с ней записи;
- уровень индексирования — сущности, специфичные для разрабатываемого плагина: «таблица ГВИ», «запись в таблице ГВИ» (непосредственно индексные данные), а также вспомогательные таблицы метаданных и статуса построения ГВИ;

Схема позволяет проследить полный жизненный цикл обработки запроса с использованием глобального вторичного индекса: от пользователя через драйвер и инстансы до индексных структур, а также отражает механизмы обновления и контроля целостности. Благодаря включению специализированных таблиц (метаданных и статуса построения) модель учитывает особенности распределенной реализации глобальных индексов, что соответствует целям работы, заявленным в главе 1.

Количество выделенных сущностей (14) является достаточным для описания предметной области: с одной стороны, оно не избыточно (каждая сущность имеет четкую семантику), с другой — не упускает важные детали, такие как механизмы построения индекса в распределенной среде. Все атрибуты сущностей отражают значимые характеристики объектов, необходимые для дальнейшего проектирования.

2.4 Оценка качества артефакта

Оценка качества инфологической схемы проводилась по следующим критериям:

- полнота — схема включает все сущности, упомянутые в вербальном описании предметной области, а также дополнительные элементы, необходимые для реализации глобальных индексов;
- непротиворечивость — связи между сущностями логически обоснованы и не противоречат архитектуре СУБД Picodata. Все связи имеют указанную мощность, что исключает неоднозначность;
- адекватность — модель адекватно отражает реальные процессы функционирования распределенной СУБД и механизмы работы с индексами;
- нормализация — структура сущностей допускает приведение к третьей нормальной форме при переходе к физической модели данных;
- пригодность для проектирования — схема может служить непосредственной основой для разработки логической и физической моделей данных плагина. На ее основе можно определить структуры хранения индексных данных, а также спроектировать алгоритмы обновления и поиска. Это соответствует цели использования артефакта как промежуточного звена между вербальным описанием и архитектурой.

На основе перечисленных критериев качество инфологической схемы оценивается как высокое. Модель полностью выполняет свою функцию — формализует знания о предметной области и создает фундамент для дальнейшего проектирования программного продукта.

3 Модель функционирования устройства, в которую внедряется продукт

4 Модель процессов функционирования продукта и его составных частей

5 Описание архитектуры программного обеспечения

6 Программа и методики испытаний ПО в составе основных сведений, позволяющих показать пути проверки достижения заданного качества программного обеспечения

ЗАКЛЮЧЕНИЕ

Заключение должно содержать:

- краткие выводы по результатам выполненной НИР или отдельных ее этапов;
- оценку полноты решений поставленных задач;
- разработку рекомендаций и исходных данных по конкретному использованию результатов НИР;
- результаты оценки технико-экономической эффективности внедрения;
- результаты оценки научно-технического уровня выполненной НИР в сравнении с лучшими достижениями в этой области.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Chen P. P.-S. The entity-relationship model—toward a unified view of data // ACM Transactions on Database Systems. Association for Computing Machinery (ACM), 1976. Т. 1, № 1. Сс. 9–36.

5.10.1 Список должен содержать сведения об источниках, использованных при составлении отчета. Сведения об источниках приводятся в соответствии с требованиями ГОСТ 7.1, ГОСТ 7.80, ГОСТ 7.82.

5.10.2 Список использованных источников должен включать библиографические записи на документы, использованные при составлении отчета, ссылки на которые оформляют арабскими цифрами в квадратных скобках. Список использованных источников оформляют в соответствии с 6.16.