

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ
АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ)»

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
ПО ДИСЦИПЛИНЕ «ПРОГРАММНАЯ ИНЖЕНЕРИЯ»

по теме:

РЕАЛИЗАЦИЯ ГЛОБАЛЬНОГО ВТОРИЧНОГО ИНДЕКСА И
СРАВНИТЕЛЬНЫЙ АНАЛИЗ ЕГО ПРОИЗВОДИТЕЛЬНОСТИ С
ЛОКАЛЬНЫМИ ИНДЕКСАМИ В РАСПРЕДЕЛЕННОЙ СУБД PICODATA

Преподаватель

подпись, дата

Кубраков Д.В.

Студент

подпись, дата

Клименко В.М.

СОДЕРЖАНИЕ

1	Вербальное описание области, направления работы, места и роли продукта, план работы	4
1.1	Системы управления базами данных	4
1.2	Системы массового обслуживания	4
1.3	Проблема поиска	5
1.4	План решения проблемы	5
2	Инфологическая схема предметной области	7
2.1	Диаграмма «сущность-связь»	7
3	Математическая модель функционирования СУБД Picodata как СМО . . .	8
3.1	Параметры расчетов	8
3.2	Функционирование с локальным индексом	8
3.2.1	Математическая модель функционирования	8
3.2.2	Теоретический расчет эффективности СМО	8
3.3	Функционирование с распределенным индексом	8
3.3.1	Математическая модель функционирования	8
3.3.2	Теоретический расчет эффективности СМО	8
3.4	Результат расчетов и сравнение	8
4	Модель функционирования системы тестирования	9
4.1	Контекстная диаграмма	9
4.2	Диаграмма потока данных	9
4.2.1	Функциональная декомпозиция	9
5	Архитектура плагина распределенного индекса	10
5.1	Верхнеуровневое описание архитектуры СУБД Picodata	10
5.2	Архитектура плагина	10
5.2.1	Представление данных	10
5.2.2	Описание алгоритмов распределенного индекса	10

6	Архитектура системы тестирования индексных структур	11
6.1	Общие сведения	11
6.2	Структурные представления	11
6.3	Архитектура решения	11
6.3.1	Основные положения архитектуры	11
6.3.2	Диаграмма развертывания	11
6.3.3	Представление данных	11

1 Вербальное описание области, направления работы, места и роли продукта, план работы

Для понимания прикладной области продукта НИР, нужно рассмотреть две сущности: системы управления базами данных (СУБД) и системами массового обслуживания (СМО).

1.1 Системы управления базами данных

Две единственные задачи СУБД — обновлять (вставка и удаление) пользовательские данные и в будущем искать среди них определенные записи. В реляционных СУБД есть понятие первичного ключа списка хранимых структур (таблиц). Первичный ключ представляет из себя набор полей структур, по значению которого запись в таблице определяется однозначно. Имея это знание, в памяти подавляющего большинства СУБД поддерживается дополнительная структура данных, позволяющая ускорить поиск по первичному ключу — индекс.

Однако, часто возникает задача поиска записи по неидентифицирующим (вторичным) полям, что наталкивает на мысль использования подобной структуры данных, с единственным различием (в общем случае) — неоднозначностью определения записи.

1.2 Системы массового обслуживания

СМО сталкиваются с вызовом эффективной обработки потока заявок, поступающих в случайные моменты времени. В ситуации, когда покупка более производительного аппаратного обеспечения (вертикальное масштабирование) одноканальной СМО становится слишком затратным (легче купить второе такое же обеспечение) или по-просту невозможным (ввиду законов физики и научного прогресса), переход на многоканальность ради увеличения скорости обработки потока заявок — единственный выход.

Распределенная реляционная СУБД Picodata является многоканальной СМО. Ее многоканальность проявляется распределением по множеству независимых серверов (шардированием) данных в зависимости от значения первичного ключа.

1.3 Проблема поиска

Положим, что базовая задача поиска в СУБД является задача поиска по одному значению первичного или вторичного ключа. Распределенность СУБД Picodata в виде шардирования данных оптимизирует задачу поиска по первичному ключу, так как, если данные равномерно распределены по всем узлам кластера, в среднем, если положить что:

- количество данных в искомой таблице равна D ,
- количество узлов в кластере равна N ,
- ПО подключения к СУБД (драйвер) знает функцию которая по значению первичного ключа может определить конкретный узел, в котором должна храниться запись, называемой функцией шардирования,

то поиск будет происходить среди $\frac{D}{N}$ записей, в то время, когда нераспределенным СУБД пришлось бы производить его среди полного набора записей D .

Однако, в СУБД Picodata нет решения такой же эффективности оптимизации поиска по вторичным ключам. Сейчас, при поиске происходит широкополосный опрос кластера с поиском в локальных индексах, то есть среди всех данных D , N серверов параллельно начинают искать запрашиваемую запись — каждая машина совершает поиск среди своей части $\frac{D}{N}$ записей.

Рассуждение выше наталкивает нас на мысль о том, что, например, если значение вторичного ключа так же однозначно определяет запись, как и первичный индекс (что нередкость), то количество совершенной бесполезной работы при подобном подходе увеличивается с количеством узлов (N) кластера линейно.

Помимо этого, при росте числа узлов в кластере, ситуация становится хуже в разы из-за линейного характера роста нагрузки не только на ЦПУ, но и на сеть.

1.4 План решения проблемы

Исходя из этого, было решено провести исследовательскую работу по изучению работоспособности распределенной индексной структуры в СУБД

Picodata. Идея заключается в заведении специальной структуры, которая будет шардирована по значениям вторичного ключа индексируемой таблицы.

План работ следующий:

- 1) полно описать СУБД Picodata с предлагаемой индексной структурой и без как СМО;
- 2) построить математическую модель СМО (см Вентцель Е.С. «Исследование операций: задачи, принципы, методология», глава 6) для СУБД Picodata с предлагаемой индексной структурой и без: предоставить формулы расчета теоретических показателей эффективности СМО (описания способности справляться с потоком заявок);
- 3) провести теоретический расчет показателей эффективности СМО;
- 4) разработать ПО, реализующее математическую модель в виде плагина к СУБД Picodata и тестирующее ПО для проведения экспериментов;
- 5) провести эксперименты для снятия показателей эффективности СМО на разработанном ПО при небольшом размере кластера, сравнить полученные результаты с теоретическим расчетом, объяснить расхождения, и сделать выводы — провести границы применимости распределенного индекса;
- 6) решить обратную задачу построения теоретических показателей эффективности — составить перечень рекомендаций по использованию распределенной индексной структуры.

2 Инфологическая схема предметной области

2.1 Диаграмма «сущность-связь»

3 Математическая модель функционирования СУБД Picodata как СМО

3.1 Параметры расчетов

3.2 Функционирование с локальным индексом

3.2.1 Математическая модель функционирования

3.2.2 Теоретический расчет эффективности СМО

3.3 Функционирование с распределенным индексом

3.3.1 Математическая модель функционирования

3.3.2 Теоретический расчет эффективности СМО

3.4 Результат расчетов и сравнение

4 Модель функционирования системы тестирования

4.1 Контекстная диаграмма

4.2 Диаграмма потока данных

4.2.1 Функциональная декомпозиция

5 Архитектура плагина распределенного индекса

5.1 Верхнеуровневое описание архитектуры СУБД Picodata

5.2 Архитектура плагина

5.2.1 Представление данных

5.2.2 Описание алгоритмов распределенного индекса

6 Архитектура системы тестирования индексных структур

6.1 Общие сведения

6.2 Структурные представления

6.3 Архитектура решения

6.3.1 Основные положения архитектуры

6.3.2 Диаграмма развертывания

6.3.3 Представление данных