

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ
АВИАЦИОННЫЙ ИНСТИТУТ (НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ)»

ОТЧЁТ
О ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ
по теме:
РЕАЛИЗАЦИЯ ГЛОБАЛЬНОГО ВТОРИЧНОГО ИНДЕКСА И
СРАВНИТЕЛЬНЫЙ АНАЛИЗ ЕГО ПРОИЗВОДИТЕЛЬНОСТИ С
ЛОКАЛЬНЫМИ ИНДЕКСАМИ В РАСПРЕДЕЛЕННОЙ СУБД PICODATA

Руководитель НИР,
Канд. техн. наук, доц.

подпись, дата

Романенков Д.В.

Исполнитель НИР,
Студент группы
М8О-403Б-22

подпись, дата

Клименко В.М.

РЕФЕРАТ

Отчёт 74 с., 5 рис., 2 табл., 16 ист.

РАСПРЕДЕЛЕННЫЕ СУБД, БАЗЫ ДАННЫХ, ВТОРИЧНЫЙ
ИНДЕКС, ГЛОБАЛЬНЫЙ ВТОРИЧНЫЙ ИНДЕКС, МАТЕМАТИЧЕСКОЕ
МОДЕЛИРОВАНИЕ, СИСТЕМЫ МАССОВОГО ОБСЛУЖИВАНИЯ

СОДЕРЖАНИЕ

Термины и определения	6
Перечень сокращений и обозначений	7
1 Вербальное описание области, направления работы, места и роли продукта, план работы	8
1.1 Распределенные системы управления базами данных	8
1.2 Системы массового обслуживания	8
1.3 Проблема поиска	9
1.4 Решение проблемы	10
1.5 Место и роль продукта ВКР	10
2 Описание предметной области	12
2.1 Верхнеуровневое описание СУБД Picodata	12
2.1.1 Сегментирование	13
2.2 Диаграмма «сущность-связь»	14
2.2.1 Описание условных обозначений	15
2.2.2 Описание сущностей	15
2.2.3 Описание связей	16
3 Математическая модель функционирования СУБД Picodata как СМО . .	18
3.1 СУБД Picodata как СМО	18
3.1.1 Показатели эффективности	20
3.2 Общие положения модели	21
3.3 Поиск в локальном индексе	23
3.3.1 Расчет показателей эффективности	32
3.4 Поиск в глобальном индексе	34
3.4.1 Расчет показателей эффективностей	44
3.5 Обновление в локальном индексе	47
3.6 Расчет параметров эффективности	52

3.7	Обновление в глобальном индексе	55
3.8	Расчет параметров эффективности	60
3.9	Результат расчетов и сравнение	63
3.9.1	Качественное сравнение	63
3.9.2	Количественное сравнение	64
3.9.3	Выводы и область предпочтительности	66
4	Модель функционирования плагина распределенного индекса	68
4.1	Контекстная диаграмма	68
4.2	Диаграмма потоков данных	68
4.2.1	Функциональная декомпозиция	68
5	Архитектура плагина распределенного индекса	69
5.1	Архитектура плагина	69
5.1.1	Диаграмма развертывания	69
5.1.2	Представление данных	69
5.1.3	Описание алгоритмов	69
6	Описание способов определения показателей качества ПО	70
6.1	Показатели качества	70
6.2	Способы определения показателей качества	70
7	Программа и методики испытаний ПО	71
7.1	Модель функционирования системы тестирования	71
7.1.1	Контекстная диаграмма	71
7.1.2	Диаграмма потоков данных	71
7.2	Архитектура системы тестирования индексных структур	71
7.2.1	Общие сведения	71
7.2.2	Структурные представления	71
7.2.3	Архитектура решения	71

7.3 Сравнение полученных результатов с математическими моделями	71
Заключение	72
Список использованных источников	73

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчете о ВКР применяют следующие термины с соответствующими определениями.

Узел — один запущенный процесс базы данных

Мастер — узел, принимающий запросы на запись и чтение

Реплика — узел, принимающий запросы только на чтение

Набор реплик — узлы, хранящие одинаковую часть данных, среди которых один является мастером, а остальные являются репликами, применяющими поток изменений от мастера

Сегментирование — разбиение данных по наборам реплик

Бакет — единица балансировки. Виртуальная сущность, к которой однозначно привязаны данные

Таблица — совокупность связанных данных, хранящихся в структурированном виде

Первичный ключ — поля таблицы, по которым уникально идентифицируются записи

Вторичный ключ — поля таблицы, по которым неуникально идентифицируются записи

Ключ сегментирования — поля таблицы, по которым происходит определение ее бакета, чаще всего является первичным ключом

Сегментированная таблица — таблица, данные которой распределены между набором реплик

Кластер — сеть набора узлов, предоставляющий доступ к единой СУБД

Плагин — единица программного обеспечения, представленная динамической библиотекой, расширяющая функционал узла

Драйвер — программное обеспечение, предоставляющее интерфейс взаимодействия с кластером

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

В настоящем отчете о ВКР применяют следующие сокращения и обозначения.

СУБД — система управления базами данных

ПО — программное обеспечение

ОЗУ — оперативное запоминающее устройство

ЦПУ — центральное процессорное устройство

ЛВИ — локальный вторичный индекс --- вторичный индекс, сегментирование которого зависит от ключа сегментирования индексируемой таблицы

ГВИ — глобальный вторичный индекс --- вторичный индекс, сегментирование которого зависит от вторичного ключа индексируемой таблицы

1 Вербальное описание области, направления работы, места и роли продукта, план работы

Для понимания прикладной области продукта ВКР, нужно рассмотреть две сущности: распределенные системы управления базами данных (СУБД) и системы массового обслуживания (СМО).

1.1 Распределенные системы управления базами данных

Единственные задачи СУБД как хранилища — обновлять пользовательские данные и в будущем искать среди них определенные записи. Для быстрого поиска в памяти подавляющего большинства СУБД поддерживается дополнительная структура данных, строимая над таблицей — индекс.

Индексы могут быть построены над двумя видами ключей:

- первичными ключами — набору полей, уникально идентифицирующими записи в таблице;
- вторичными ключами — набору полей, неуникально идентифицирующими записи в таблице.

В пункте 1.3 будет показано почему это разделение важно в рамках распределенных СУБД.

1.2 Системы массового обслуживания

Электронные СМО сталкиваются с вызовом эффективной обработки потока заявок, поступающих в случайные моменты времени. В ситуации, когда покупка более производительного аппаратного обеспечения (вертикальное масштабирование) одноканальной СМО становится слишком затратным или попросту невозможным (ввиду законов физики и научного прогресса), переход на многоканальность ради увеличения скорости обработки потока заявок — единственный выход.

Распределенная реляционная СУБД Picodata является многоканальной СМО. Ее многоканальность проявляется в сегментировании данных по множеству независимых серверов по значению ключа сегментирования.

1.3 Проблема поиска

Положим, что базовой задачей поиска в СУБД является задача поиска по значению первичного или вторичного ключа. Сегментирование данных в СУБД Picodata позволяет оптимизировать задачу поиска по ключу сегментирования. Обычно ключ сегментирования является и первичным ключом таблицы, поэтому считаем, что в нашем случае это условие тоже выполняется. Если:

- данные равномерно распределены по всем наборам реплик кластера,
- количество данных в искомой таблице равно D ,
- количество наборов реплик в кластере равно N ,
- ПО подключения к СУБД (далее — драйвер) знает функцию (далее — функция сегментирования), которая по значению первичного ключа определяет конкретный набор реплик кластера, в котором должна храниться запись,

то поиск в структуре данных, хранящей таблицу с искомой записью будет происходить среди $\frac{D}{N}$ записей, в то время, когда нераспределенным СУБД пришлось бы производить его среди полного набора записей D .

Однако, в СУБД Picodata нет решения задачи оптимизации поиска по вторичным ключам такой же эффективности. Сейчас происходит опрос кластера с поиском в локальных индексах. То есть среди всех данных D , N процессов параллельно ищут запрашиваемую запись — каждая машина совершает поиск среди $\frac{D}{N}$ записей.

Рассуждение выше наталкивает на мысль о том, что, например, если значение вторичного ключа так же однозначно определяет запись, как и первичный индекс (что нередкость), то количество совершённой бесполезной работы при подобном подходе увеличивается пропорционально количеству набору реплик кластера (N). Помимо этого, количество сетевых запросов растёт пропорционально количеству набору реплик кластера, что тоже в высокой степени влияет на быстроедействие поиска в СУБД.

1.4 Решение проблемы

Исходя из этого, было решено провести исследовательскую работу по изучению работоспособности глобального вторичного индекса (ГВИ) в СУБД Picodata. Идея заключается в сегментировании индексной структуры по значениям вторичного ключа индексируемой таблицы.

План работ следующий:

- 1) полно описать СУБД Picodata с предлагаемой индексной структурой и без как СМО;
- 2) построить математическую модель СМО для СУБД Picodata с предлагаемой индексной структурой и без: предоставить формулы расчета теоретических показателей эффективности СМО;
- 3) провести теоретический расчет показателей эффективности СМО;
- 4) разработать ПО, реализующее математическую модель в виде плагина к СУБД Picodata и тестирующее ПО для проведения экспериментов;
- 5) провести эксперименты для снятия показателей эффективности СМО на разработанном ПО при небольшом размере кластера, сравнить полученные результаты с теоретическим расчетом, объяснить расхождения, и сделать выводы — провести границы применимости распределенного индекса;
- 6) решить обратную задачу построения теоретических показателей эффективности — составить перечень рекомендаций по использованию распределенной индексной структуры.

1.5 Место и роль продукта ВКР

Основным продуктом ВКР является плагин к СУБД Picodata, добавляющий функционал глобальных индексов и интерфейс работы с ними.

Функциональные возможности плагина:

- построение глобального индекса;
- удаление глобального индекса;
- выполнение поисковых запросов с использованием глобального индекса.

Целевые пользователи плагина:

- администраторы СУБД Picodata;
- разработчики распределенных приложений.

Побочными продуктами ВКР выступают:

- 1) математическая модель индексных структур СУБД Picodata;
- 2) показатели эффективности различных индексных структур;
- 3) методические рекомендации по выбору типа индекса;
- 4) драйвер использования плагина;
- 5) результаты нагрузочного тестирования.

2 Описание предметной области

2.1 Верхнеуровневое описание СУБД Picodata

Модель функционирования СУБД Picodata представлена текстовым верхнеуровневым описанием архитектуры, некоторых особенностей и внутренних процессов.

Picodata — это распределенная СУБД, основной фокус которой является отказоустойчивое хранение сегментированных данных. Ее распределенность проявляется при соединении через сеть нескольких запущенных процессов Picodata (узлов): они собираются в кластер — единую СУБД.

Каждый кластер состоит из нескольких наборов узлов, в каждом наборе мастер-узел обрабатывает пользовательские запросы, а остальные являются его репликами. Разделение данных между наборами узлов позволяет примерно равномерно распределять нагрузку по кластеру. Например, при обновлении одной записи, обновляется только часть базы данных, расположенная на одном наборе реплик.

Picodata представляет из себя многопоточное приложение. Главным потоком является `tx_thread` — из интересующего нас, в нем происходит доступ к данным и запускается код плагинов.

При использовании резидентного движка хранения `memtx`, обновления таблицы записываются в журнал упреждающей записи, а индексы хранятся в структуре данных B+*-дерево (смесь вариантов B+- и B*- деревьев) в ОЗУ. При построении вторичного индекса, ключом становится конкатенация значения вторичного ключа с первичным, так что записи с совпадающими вторичными ключами идут подряд. В листе дерева хранится указатель на полную запись в таблице.

Среда потока доступа к данным исполнения является асинхронной, то есть используется кооперативная многозадачность, что позволяет максимально эффективно использовать ЦПУ во время ожидания ответа дискового хранилища или сетевого интерфейса.

2.1.1 Сегментирование

Особо важно понимать механизм сегментирования в СУБД Picodata. Равномерность распределения данных, а также предотвращение лишних сетевых запросов при изменении количества наборов реплик достигается благодаря виртуальным сущностям — бакетам, которые однозначно идентифицируются натуральным числом. Количество бакетов в кластере задается единожды при запуске первого узла и не изменяется впоследствии.

Среди наборов реплик бакеты поделены поровну, например, если в кластере 3 набора реплик, а бакетов 3000, то бакеты поделены по 1000 штук (например, равными последовательными отрезками), то есть:

- первому набору реплик принадлежат бакеты с номерами от 1 по 1000;
- второму — от 1001 по 2000;
- третьему — от 2001 по 3000.

При создании сегментированной таблицы, задается набор атрибутов, называемый ключом сегментирования (обычно им же является первичный ключ) — это поля записи, на основе которых вычисляется бакет каждой записи. Номер бакета равен остатку от деления значения хеш-функции ключа сегментирования.

Любые пользовательские запросы, пришедшие на узел, преобразовываются в план исполнения — набор операций, который должен исполнить движок хранения, чтобы ответить на запрос. Если для исполнения запроса должно быть задействовано несколько наборов реплик, то на мастера каждого набора реплик отправляется план исполнения, который исполняется в локальном движке хранения, например, в случае memtx, это обход и обновление B+*-дерева в ОЗУ.

Более подробное устройство индекса, построенного на B+*-дереве можно прочитать в [1–4].

Полную документацию СУБД Picodata можно прочитать на портале документации компании [5]. Подробнее про концепты распределенных систем можно прочитать в [6].

2.2 Диаграмма «сущность-связь»

Инфологическая схема предметной области представлена в виде диаграммы «сущность-связь» на рисунке 1.




Рисунок 1 — ER-диаграмма предметной области продукта ВКР

2.2.1 Описание условных обозначений

Диаграмма выполнена в нотации Чена [7]. Используемые обозначения:

- прямоугольник — сущность;
- ромб — связь;
- овал — атрибут сущности;
- 1:1 — связь «один к одному»;
- 1:N — связь «один ко многим».

2.2.2 Описание сущностей

В модели выделены следующие сущности и их атрибуты (если они есть):

- пользователь — лицо, инициирующее запросы к СУБД;
- драйвер — ПО, предоставляющее интерфейс взаимодействия с СУБД;
- база данных — кластер СУБД Picodata;
- набор реплик — набор узлов, хранящих одинаковую часть данных, в котором один является мастером, а остальные являются репликами, принимающими и применяющими поток изменений от мастера.

Атрибуты:

- распределение бакетов — список бакетов, принадлежащих данному набор реплику;
- узел — один запущенный процесс Picodata. Атрибуты:
 - является мастером — булево значение, показывающее роль в наборе реплик: мастер или реплика;
- движок хранения — механизм хранения данных;
- пользовательская таблица — совокупность связанных данных о пользователях сервиса, хранящихся в структурированном виде.

Атрибуты:

- название — идентификатор таблицы;
- первичный ключ — список идентификаторов полей, уникально определяющих запись;

- записи — пользовательские данные;
- список индексов — набор построенных над таблицей индексов;
- ЛВИ (локальный вторичный индекс) — индексная структура, сегментированная как и индексируемая таблица. Атрибуты:
 - название — идентификатор индекса;
 - записи таблицы — проиндексированные пользовательские данные;
 - параметры индекса — значения настроек индекса: уникальность значений вторичных ключей;
- плагин — единица программного обеспечения, расширяющая функционал узла;
- ГВИ (глобальный вторичный индекс) — индексная структура, сегментированная по индексируемым полям. Атрибуты:
 - название — идентификатор индекса;
 - записи таблицы — проиндексированные пользовательские данные;
 - параметры индекса — значения настроек индекса: уникальность значений вторичных ключей;

2.2.3 Описание связей

В модели выделены следующие связи между сущностями:

- пользователь — драйвер: пользователь использует драйвер для отправления запросов к СУБД (1:1);
- драйвер — база данных: драйвер посылает запросы в базу данных (1:1);
- база данных — набор реплик: база данных состоит из наборов реплик (1:N);
- набор реплик — узел: набор реплик состоит из узлов (1:N);
- узел — движок хранения: узел имеет несколько движков хранения (1:N);
- движок хранения — пользовательская таблица: движок хранения содержит множество пользовательских таблиц (1:N);

- движок хранения — ЛВИ: движок хранения содержит множество локальных вторичных индексов (1:N);
- движок хранения — ГВИ: движок хранения содержит множество глобальных вторичных индексов (1:N);
- узел — плагин: узел запускает плагин построения глобальных вторичных индексов (1:1);
- плагин — движок хранения: плагин использует движки хранения для построения глобальных вторичных индексов (1:N);
- плагин — ГВИ: плагин строит множество глобальных вторичных индексов (1:N).

3 Математическая модель функционирования СУБД Picodata как СМО

В данной главе построена математическая модель СУБД Picodata, основываясь на теории массового обслуживания. Рассматриваются локальный вторичный индекс (ЛВИ) — единственная индексная структура, реализованная в Picodata на данный момент, и новая, предлагаемая структура — глобальный вторичный индекс (ГВИ) в контексте обновления данных и поиска по ним.

Это необходимо для математического обоснования создания альтернативного алгоритма индексирования данных в распределенной СУБД Picodata.

В качестве материала для изучения теории массового обслуживания были использованы [8–10].

3.1 СУБД Picodata как СМО

В контексте работы с индексами в СУБД Picodata, удобно разделить каждый узел на две роли — координатора и исполнителя. Такое разделение приведено сугубо для удобства расчетов математической модели, на деле же все узлы являются одним и тем же приложением с идентичной логикой. Роль узла «зафиксирована» только на время обработки одного запроса и зависит исключительно от выбора пользователем узла, который примет запрос, то есть координатора.

Алгоритм работы координатора представлен следующим циклом:

- 1) принять запрос пользователя;
- 2) составить планы исполнения для мастеров нужных наборов реплик (исполнителей);
- 3) разослать планы исполнения исполнителям;
- 4) дождаться результата от исполнителей;
- 5) объединить полученные данные;
- 6) отправить пользователю запрашиваемые данные.

Работа исполнителя происходит между пунктами 3 и 4 работы координатора и ее алгоритм представлен следующим циклом:

- 1) принять план исполнения от координатора;
- 2) исполнить план с помощью движка хранения на своей части данных;
- 3) отправить результат исполнения обратно на координатора.

Получается координатор «управляет» всем кластером на время запроса, а исполнитель — только локальными структурами данных. Координатор бьет изначальный запрос на подзадачи, которые решают несколько исполнителей.

В качестве СМО будет описан именно исполнитель, так как работа координатора занимает малое время. Это будет показано в пункте 3.3.

Чтобы избежать излишней сложности модели, постановим, что каждый набор реплик кластера состоит из одного узла. Это не влияет на точность модели, так как реплики являются резервным хранилищем, на котором не исполняются запросы.

В таблице 1 приведена характеристика узла СУБД Picodata как СМО. Положения таблицы верны для обеих индексных структур и являются справедливыми и для поиска, и для обновления:

Таблица 1 — Характеристика роли координатора узла в СУБД Picodata как СМО

Элемент СМО	Элемент СУБД
Канал обслуживания	tx_thread
Поток заявок	Запросы на поиск или обновление данных сегментированной таблицы
Поток ответов	Отфильтрованные данные таблицы в случае поиска и подтверждение операции в случае обновления таблицы
Дисциплина очереди	Очередь бесконечной длины с ограничением по времени ожидания (таймаут заявки)

Для простоты модели, допустим, что в течение работы количество заявок является случайной величиной следующей закону распределения Пуассона (время между заявками следует экспоненциальному закону распределения) с параметром λ , причем этот поток обладает свойствами:

- стационарности — число заявок не зависит от времени начала работы СМО;
- ординарности — в бесконечно малый промежуток времени шанс получения нескольких заявок стремится к нулю;
- является потоком без последствия — количество заявок в настоящем не зависит от количества заявок в прошлом.

Более подробное описание этих свойств можно найти в [9].

Для расчета задержки сетевых запросов, будем использовать случайную величину с гамма-распределением согласно исследованиям [11,12].

В контексте поиска по индексу, элементарной задачей является нахождение записей с фильтрацией по значению одного вторичного ключа.

В контексте обновления индекса, элементарной задачей является обновление одной записи во вторичном индексе.

Для расчета времени работы узла, будем ориентироваться на количество операций сравнения ключей при поиске и обновлении в B^{+} -дереве, деленное на частоту проведения этих операций ЦПУ и количество операций загрузки данных по указателям, деленное на частоту загрузки блока памяти из запоминающего устройства.

Также, будем учитывать время, потраченное на запись в журнал упреждающей записи, и скажем, что оно константное, так как представляет из себя просто добавление байтов в конец файла, указатель на конец которого известен в момент записи.

Итого, кластер СУБД Picodata моделируется как N независимых (из-за различных наборов данных) СМО $M/G/1$ согласно нотации приведенной в [10], где N — это количество наборов реплик в кластере.

3.1.1 Показатели эффективности

Возьмем следующие показатели эффективности СМО:

- максимальное количество запросов в секунду;
- вероятность таймаута заявки;
- среднее время обслуживания заявки;

- среднее время ожидания заявки в очереди.

Для построения расчетов показателей эффективности будем использовать следующие параметры:

- количество наборов реплик в кластере N ;
- объем пользовательских данных D (количество записей в таблице);
- количество уникальных вторичных ключей (кардинальность множества вторичных ключей) K ;
- размер одной записи r (в байтах);
- частота операций сравнения в секунду на ЦПУ f_{cpu} ;
- частота операций загрузки и записи данных по указателю из устройства памяти f_{mem} ;
- порядок B+*-дерева m ;
- время таймаута T_{timeout} в секундах;
- скорость сети между пользователем и кластером СУБД v_{user} в байтах в секунду;
- скорость сети между узлами v_{cluster} в байтах в секунду;
- значения параметров случайных величин:
 - λ_{search} и λ_{update} — интенсивности потоков заявок (заявок в секунду) на поиск и обновление соответственно;
 - k_{user} и θ_{user} — параметры гамма-распределения $\Gamma(k_{\text{user}}, \theta_{\text{user}})$ времени сетевой задержки между пользователем и кластером СУБД. Математическое ожидание такого распределения равно $k_{\text{user}}\theta_{\text{user}}$, дисперсия равна $k_{\text{user}}\theta_{\text{user}}^2$;
 - k_{cluster} и θ_{cluster} — параметры гамма-распределения $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$ времени сетевой задержки между узлами СУБД. Математическое ожидание такого распределения равно $k_{\text{cluster}}\theta_{\text{cluster}}$, дисперсия равна $k_{\text{cluster}}\theta_{\text{cluster}}^2$.

3.2 Общие положения модели

Для обеих индексных структур и обоих видов запросов взаимодействие пользователя на уровне кластера выглядит одинаково: координатор принимает запрос пользователя, по некому алгоритму

собирает данные со всех исполнителей и возвращает их пользователю. Для удобства, расчет времени этого взаимодействия вынесено в лемму 3.2.1.

Лемма 3.2.1 (*о времени ожидания пользователя при запросе в СУБД Picodata*)

Время ожидания пользователя T^{user} исполнения заявки является случайной величиной и рассчитывается по следующей формуле:

$$T^{\text{user}} = t_{\text{request}}^{\text{user}} + \frac{Q}{v_{\text{user}}} + W^{\text{coordinate}} + t_{\text{response}}^{\text{user}} + \frac{R}{v_{\text{user}}}, \quad (1)$$

где:

- $t_{\text{request}}^{\text{user}}$ — время задержки передачи запроса от пользователя к СУБД по сети;
- Q — размер пользовательского запроса;
- v_{user} — скорость передачи данных между кластером СУБД и пользователем;
- $W^{\text{coordinate}}$ — время ожидания обработки запроса координатором;
- $t_{\text{response}}^{\text{user}}$ — время задержки передачи результата от СУБД к пользователю по сети;
- R — размер результата запроса.

Доказательство

Взаимодействие пользователя с кластером начинается с отправки запроса по сети.

Задержку сети между пользователем и СУБД, то есть время между отправлением первого байта пользователем и его получением СУБД, мы моделируем как гамма-распределение, согласно рассуждениям в описании координатора, обозначим ее как $t_{\text{request}}^{\text{user}} \sim \Gamma(k_{\text{user}}, \theta_{\text{user}})$.

Передача по сети запроса, весящего Q байтов со скоростью v_{user} байтов в секунду занимает Q/v_{user} секунд.

Положим, что время ожидание в очереди и обработки запроса координатором занимает $W^{\text{coordinate}}$ секунд.

После получения результата в СУБД, он должен быть отправлен обратно пользователю по сети. Задержку сети между СУБД и пользователем моделируем так же — обозначим ее как $t_{\text{response}}^{\text{user}} \sim \Gamma(k_{\text{user}}, \theta_{\text{user}})$.

Передача по сети результата, весящего R байтов со скоростью v_{user} байтов в секунду занимает R/v_{user} секунд.

При получении результата, взаимодействие пользователя с кластером кончается.

Итого, время ожидания пользователя, которое мы обозначим T^{user} является суммой вышеупомянутых величин:

$$T^{\text{user}} = t_{\text{request}}^{\text{user}} + \frac{Q}{v_{\text{user}}} + W^{\text{coordinate}} + t_{\text{response}}^{\text{user}} + \frac{R}{v_{\text{user}}}. \quad (2)$$

Часть суммы — случайная величина, значит и вся сумма — случайная величина. $\square$

В пунктах 3.3, 3.4, 3.5 и 3.7 рассматриваются алгоритмы конкретных индексных структур и запросов. Переменные, специфичные индексной структуре и запросу будут помечены в нижнем индексе. То есть, например, время ожидания исполнения запроса координатора при поиске в ЛВИ будет обозначаться $W_{\text{search,LSI}}^{\text{coordinate}}$, а время ожидания пользователем обновления ГВИ будет обозначаться $T_{\text{update,GSI}}^{\text{user}}$.

Также, в вышеупомянутых пунктах диаграммы последовательности соответствующих алгоритмов на кластере.

Каждая стрелка, переходящая между активностями (activity из UML) объектов (object из UML) представляет из себя один сетевой запрос.

На диаграммах рассмотрены максимально обобщенные топологии кластера, поэтому, блоками с пометкой «цикл» показаны сообщения (messages из UML), которые повторяются, внутри этих блоков, в квадратных скобках написаны параметры цикла.

Нотация описана в работе [13].

3.3 Поиск в локальном индексе

Локальные индексы устроены следующим образом:

- как сказано в пункте 2.1, данные сегментированных таблиц распределены примерно равномерно среди наборов реплик, а принадлежность записи к набору реплик определяется значением ключа сегментирования;
- часть индекса находится на каждом наборе реплик, причем данные индекса поделены по тому же ключу сегментирования, что и индексируемая таблица.

Алгоритм поиска в кластере с такой индексной структурой выглядит следующим образом:

- 1) координатор принимает пользовательский запрос, составляет план локального поиска
- 2) координатор отправляет план локального запроса всем исполнителем (мастеру каждого набора реплик);
- 3) на каждом исполнителе происходит поиск записей по значению вторичного ключа в B^{+} -дереве части индекса;
- 4) каждый исполнитель отправляет найденные записи координатору;
- 5) координатор ждет ответов от всех исполнителей, объединяет их и отправляет найденные записи пользователю.

На рисунке 2 представлена диаграмма последовательности описанного алгоритма. На ней изображены линии жизни (lifelines из UML) следующих объектов:

- клиент — инициатор обращения к СУБД;
- координатор;
- исполнитель i — исполнитель набора реплик под номером i .




Рисунок 2 — UML Sequence диаграмма поиска в сегментированной таблице в СУБД Picodata с использованием ЛВИ

Исходя из этой диаграммы, можно рассчитать количество сетевых запросов при поиске с использованием ЛВИ ($NR_{\text{search}}^{\text{LSI}}$). Координатор отправляет план исполнения в каждый набор реплик, из этого выходит N сетевых запросов, на каждый запрос нужно отправить ответ — умножаем на два; к этому прибавим запрос поиска от клиента к координатору и ответ, итого, получим:

$$NR_{\text{search}}^{\text{LSI}} = 2N + 2. \quad (3)$$

Таким образом, архитектура ЛВИ приводит к линейной зависимости числа сетевых запросов от количества наборов реплик, что ограничивает горизонтальное масштабирование кластера при поисковых нагрузках.

Данная диаграмма наглядно показывает, что для поиска в кластере с использованием ЛВИ нужно опросить каждый набор реплик на принадлежность записи к сегментированной таблице. Это может оказаться узким горлышком при некоторых ситуациях:

- в кластере много наборов реплик;
- взаимодействие узлов происходит по нестабильной сети;
- кардинальность множества значений индексируемого атрибута стремится к количеству записей в таблице.

Следовательно, возникает необходимость архитектурного решения, позволяющего:

- уменьшить количество сетевых взаимодействий;
- устранить необходимость широковещательного запроса;
- локализовать поиск.

Теорема 3.3.1 (о времени ожидания исполнения запроса координатором при поиске в ЛВИ)

Время ожидания исполнения запроса координатором $W_{\text{search,LSI}}^{\text{coordinate}}$ является случайной величиной и рассчитывается по следующей формуле:

$$\begin{aligned}
 W_{\text{search,LSI}}^{\text{coordinate}} &= W_{\text{search,q,LSI}}^{\text{execute}} + T_{\text{search,LSI}}^{\text{coordinate}} = \\
 &= W_{\text{search,q,LSI}}^{\text{execute}} + \max_{i=1..N} [T_{\text{search,LSI},i}^{\text{coordinate}}] = W_{\text{search,q,LSI}}^{\text{execute}} + \\
 &+ \max_{i=1..N} \left[t_{\text{request},i}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{search,LSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{sr}{v_{\text{cluster}}} \right],
 \end{aligned} \tag{4}$$

где:

- $W_{\text{search,q,LSI}}^{\text{execute}}$ — время ожидания запроса в очереди исполнителя;
- $T_{\text{search,LSI},i}^{\text{coordinate}}$ — время ожидания ответа от исполнителя под номером i ;
- $t_{\text{request},i}^{\text{replicaset}}$ и $t_{\text{response},i}^{\text{replicaset}}$ — времена задержки передачи запроса между координатором и исполнителем под номером i по сети;
- P — размер плана исполнения;
- v_{cluster} — скорость передачи данных между узлами СУБД;
- $W_{\text{search,LSI}}^{\text{execute}}$ — время ожидания обработки запроса исполнителем;
- s — количество записей с искомым вторичным ключом на наборе реплик;
- r — размер одной записи.

Доказательство

Для начала рассмотрим время, которое проводится исключительно на самом координаторе.

Запрос сначала попадает в очередь исполнителя (так как координатор и исполнитель — это одно и то же приложение, то и очередь у них одна) и находится там $W_{\text{search,q,LSI}}^{\text{execute}}$ секунд.

После этого происходит составление плана запроса, время которого не учитывается, так как на практике занимает чуть больше 6 микросекунд на ЦПУ игрового ноутбука со скоростью 4.46 ГГц, что на 4 порядка меньше чем среднее время пинга домашнего роутера с передачей 56 байтов, подключенного по Wi-Fi — 23 миллисекунды. Пинг домашнего роутера занимает порядка десяти миллисекунд, так что можно предположить, что передача сообщений с результатами между узлами будет занимать не меньше времени, особенно если узлы расположены отдаленно географически.

Итого, на координаторе заявка обрабатывается $W_{\text{search},q,LSI}^{\text{execute}}$ секунд, далее он делегирует работу исполнителям.

Рассмотрим сколько времени занимает обработка поиска на исполнителях.

Составленный план запроса отправляется каждому исполнителю по сети, которых всего N штук.

Каждое отправление плана сопровождается сетевой задержкой, которая длится $t_{\text{request},i}^{\text{replicaset}}$, моделируемая как гамма-распределение $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$, аналогично лемме 3.2.1.

Положим, что план запроса весит P байтов, а скорость передачи данных между узлами кластера равна v_{cluster} байтов в секунду. Тогда весь план будет передан через P/v_{cluster} секунд.

На исполнителе время ожидания исполнения заявки, то есть время, проведенное в очереди в сумме с временем непосредственной обработки заявки обозначим как $W_{\text{search},LSI}^{\text{execute}}$.

Результат работы каждого исполнителя отправляется координатору отдельным сетевым запросом с задержкой $t_{\text{request},i}^{\text{replicaset}}$, моделируемой гамма-распределением $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

Исходя из предположения, что данные распределены равномерно (в том числе по вторичным ключам) по наборам реплик, то на каждом исполнителе находится s , равное $\frac{D}{NK}$ искомым записей.

Положим, что одна запись весит r байтов, тогда передача данных с одного исполнителя занимает $\frac{sr}{v_{\text{cluster}}}$ секунд.

Итого, время, которое занимает прием и обработка плана исполнения на одном исполнителе является следующей суммой:

$$t_{\text{request},i}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{search,LSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{sr}{v_{\text{cluster}}}, \quad (5)$$

которую мы обозначим $T_{\text{search,LSI},i}^{\text{coordinate}}$.

Координатор должен дождаться ответа от всех исполнителей, чтобы вернуть объединенный результат пользователю, так что время ожидания исполнителей равно времени ожидания самого долгого исполнителя, что является максимумом среди всех $T_{\text{search,LSI},i}^{\text{coordinate}}$.

Итого, время ожидания исполнения запроса координатором $W_{\text{search,LSI}}^{\text{coordinate}}$ рассчитывается по следующей формуле:

$$\begin{aligned} W_{\text{search,LSI}}^{\text{coordinate}} &= W_{\text{search,q,LSI}}^{\text{execute}} + T_{\text{search,LSI}}^{\text{coordinate}} = \\ &= W_{\text{search,q,LSI}}^{\text{execute}} + \max_{i=1..N} [T_{\text{search,LSI},i}^{\text{coordinate}}] = W_{\text{search,q,LSI}}^{\text{execute}} + \\ &+ \max_{i=1..N} \left[t_{\text{request},i}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{search,LSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{sr}{v_{\text{cluster}}} \right], \end{aligned} \quad (6)$$

В правой части равенства присутствуют случайные величины, так что и левая часть является случайной величиной. $\square$

Заметим, что каждая заявка на поиск порождает N заявок исполнителям, причем интенсивность потока исполнителя $\lambda_{\text{search,LSI}}^{\text{sub}}$ так же равна $\lambda_{\text{search,LSI}}$. Интенсивность потока во всем кластере суммарно равна $\lambda_{\text{search,LSI}}N$, так как для обработки одной заявки координатором, нужно обработать в N исполнителях.

Все параметры, необходимые для расчета, кроме времени ожидания обработки подзадачи исполнителем $W_{\text{search,LSI}}^{\text{execute}}$ и времени ожидания в очереди исполнителя $W_{\text{search,q,LSI}}^{\text{execute}}$ известны. Для нахождения обеих величин необходимо вычислить время обработки заявки исполнителем $T_{\text{search,LSI}}^{\text{execute}}$.

Чтобы не усложнять расчеты случайностью всех процессов поиска в $B+^*$ -дереве, будет рассмотрен худший случай поиска. Так что $T_{\text{search,LSI}}^{\text{coordinate}}$ — это скалярная величина.

На каждом исполнителе хранится по $d = \frac{D}{N}$ записей, так что поиск первой записи по вторичному ключу в B^+ -дереве требует $\log_m d$ операций перехода по указателям и $\log_m d \log_2(2m - 1)$ операций сравнения ключей.

Если рассмотреть случай, когда искомый ключ является самым правым ключом листа, при этом все листья правее имеют $\frac{2}{3}(2m - 1)$ ключей (минимальное количество ключей в узле в соответствии с определением B^+ -деревя), получаем, что чтение s записей из листовых узлов B^+ -деревя требует максимум $\frac{s-1}{\frac{2}{3}(2m-1)}$ дополнительных переходов по указателям между листьями. После нахождения искомого ключа нужно перейти по указателю на полную запись в таблице.

Итого, время решения подзадачи поиска равно:

$$T_{\text{search,LSI}}^{\text{execute}} = \frac{\log_m d \log_2(2m - 1)}{f_{\text{cpu}}} + \frac{\log_m d + 3 \cdot \frac{s-1}{4m-2} + 1}{f_{\text{mem}}}. \quad (7)$$

Теперь можно найти время ожидания в очереди исполнителя $W_{\text{search,q,LSI}}^{\text{execute}}$ и время работы над заявкой исполнителем $W_{\text{search,LSI}}^{\text{execute}}$. Для этого воспользуемся формулой Полячека-Хинчина [10].

Загрузка исполнителя равна:

$$\rho_{\text{search,LSI}}^{\text{executor}} = \lambda_{\text{search,LSI}}^{\text{sub}} \cdot T_{\text{search,LSI}}^{\text{execute}}, \quad (8)$$

значит он будет справляться с нагрузкой при $\rho_{\text{search,LSI}}^{\text{executor}} < 1$.

По формуле Полячека—Хинчина рассчитаем среднее количество заявок в исполнителе (количество заявок в очереди и ныне обслуживающихся):

$$\begin{aligned} L_{\text{search,LSI}}^{\text{execute}} &= \rho_{\text{search,LSI}}^{\text{executor}} + \frac{\rho_{\text{search,LSI}}^{\text{executor}^2} + \lambda_{\text{search,LSI}}^{\text{sub}} D [T_{\text{search,LSI}}^{\text{execute}}]}{2(1 - \rho_{\text{search,LSI}}^{\text{executor}})} = \\ &= \rho_{\text{search,LSI}}^{\text{executor}} + \frac{\rho_{\text{search,LSI}}^{\text{executor}^2}}{2(1 - \rho_{\text{search,LSI}}^{\text{executor}})}, \end{aligned} \quad (9)$$

и среднее время ожидания заявки в исполнителе в соответствии с законом Литтла, приведенным в [9,10]:

$$W_{\text{search,LSI}}^{\text{execute}} = \frac{L_{\text{search,LSI}}^{\text{execute}}}{\lambda_{\text{search}}} = T_{\text{search,LSI}}^{\text{execute}} + \frac{\rho_{\text{search,LSI}}^{\text{executor}} T_{\text{search,LSI}}^{\text{execute}}}{2(1 - \rho_{\text{search,LSI}}^{\text{executor}})}. \quad (10)$$

Время, проведенное в очереди равно времени проведенному в системе без времени обслуживания заявки, тогда:

$$W_{\text{search,q,LSI}}^{\text{execute}} = W_{\text{search,LSI}}^{\text{execute}} - T_{\text{search,LSI}}^{\text{execute}} = \frac{\rho_{\text{search,LSI}}^{\text{executor}} T_{\text{search,LSI}}^{\text{execute}}}{2(1 - \rho_{\text{search,LSI}}^{\text{executor}})}. \quad (11)$$

Оценим время работы координатора, связанное с одним исполнителем:

$$T_{\text{search,LSI},i}^{\text{coordinate}} = t_{\text{request},i}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{search,LSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{sr}{v_{\text{cluster}}}. \quad (12)$$

Только времена сетевой задержки $(t_{\text{request},i}^{\text{replicaset}}, t_{\text{response},i}^{\text{replicaset}})$ — случайные величины, остальные — скалярные, так что, согласно свойствам гамма-распределения, приведенным в [14], время работы координатора на одном наборе реплик — случайная величина, имеющая сдвинутое гамма-распределение. Случайную часть $T_{\text{search,LSI},i}^{\text{coordinate}}$ обозначим Y , а детерминированную — $C^{\text{coordinate}}$:

$$C^{\text{coordinate}} = W_{\text{search,LSI}}^{\text{execute}} + \frac{P + sr}{v_{\text{cluster}}}, \quad (13)$$

$$Y = T_{\text{search,LSI},i}^{\text{coordinate}} - C^{\text{coordinate}} \sim \Gamma(2k_{\text{cluster}}, \theta_{\text{cluster}}). \quad (14)$$

Следовательно функция распределения равна:

$$F_Y(t) = P(Y \leq t) = \frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})}. \quad (15)$$

Согласно формуле (4), время работы координатора равно:

$$T_{\text{search,LSI}}^{\text{coordinate}} = \max_{i=1..N} T_{\text{search,LSI},i}^{\text{coordinate}} \quad (16)$$

случайную часть $T_{\text{search,LSI}}^{\text{coordinate}}$ обозначим Z , максимум среди одинаковых неслучайных величин $C^{\text{coordinate}}$ равен самому себе:

$$Z = T_{\text{search,LSI}}^{\text{coordinate}} - C^{\text{coordinate}} \quad (17)$$

значит, функция распределения Z равна:

$$F_Z(t) = [F_Y(t)]^N = \left[\frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^N, \quad (18)$$

что позволяет нам численно найти моменты $T_{\text{search,LSI}}^{\text{coordinate}}$ через функцию выживания [15]:

$$M[Z] = \int_0^\infty \left(1 - \left[\frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^N \right) dt, \quad (19)$$

$$M[Z^2] = \int_0^\infty 2t \left(1 - \left[\frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^N \right) dt, \quad (20)$$

$$M[T_{\text{search,LSI}}^{\text{coordinate}}] = M[Z] + C^{\text{coordinate}}, \quad (21)$$

$$D[T_{\text{search,LSI}}^{\text{coordinate}}] = D[Z] = M[Z^2] - (M[Z])^2. \quad (22)$$

В свою очередь:

$$M[W_{\text{search,LSI}}^{\text{coordinate}}] = W_{\text{search,q,LSI}}^{\text{execute}} + M[T_{\text{search,LSI}}^{\text{coordinate}}], \quad (23)$$

$$D[W_{\text{search,LSI}}^{\text{coordinate}}] = D[T_{\text{search,LSI}}^{\text{coordinate}}] \quad (24)$$

Время задержек в $T_{\text{search,LSI}}^{\text{user}}$, обозначим за V , тогда:

$$V = t_{\text{request}}^{\text{user}} + t_{\text{response}}^{\text{user}} \sim \Gamma(2k_{\text{user}}, \theta_{\text{user}}), \quad (25)$$

из чего можно найти математическое ожидание и дисперсию времени ожидания пользователя:

$$\begin{aligned} M[T_{\text{search,LSI}}^{\text{user}}] &= M[V] + M[W_{\text{search,LSI}}^{\text{coordinate}}] + \frac{sNr}{v_{\text{user}}} = \\ &= k_{\text{user}}\theta_{\text{user}} + M[W_{\text{search,LSI}}^{\text{coordinate}}] + \frac{Q + sNr}{v_{\text{user}}}, \end{aligned} \quad (26)$$

$$\begin{aligned} D[T_{\text{search,LSI}}^{\text{user}}] &= D[V] + D[W_{\text{search,LSI}}^{\text{coordinate}}] = \\ &= k_{\text{user}}\theta_{\text{user}}^2 + D[W_{\text{search,LSI}}^{\text{coordinate}}]. \end{aligned} \quad (27)$$

3.3.1 Расчет показателей эффективности

Максимальное количество запросов в секунду достигается при максимальной загрузке системы. Так как мы договорились, что составление плана исполнения координатором не учитывается в модели, на него можно подать бесконечную нагрузку. Тогда единственным ограничивающим фактором системы является время обработки заявки исполнителем $T_{search,LSI}^{execute}$.

Для устойчивости системы, загрузка системы $\rho_{search,LSI}^{executor}$ должна не превышать единицу. По определению, загрузка системы рассчитывается по формуле (8), значит максимальная нагрузка системы рассчитывается по следующей формуле:

$$\lambda_{search,LSI}^{sub,max} = \frac{1}{T_{search,LSI}^{execute}}, \quad (28)$$

следовательно:

$$\lambda_{search,LSI}^{max} = \frac{1}{T_{search,LSI}^{execute}}. \quad (29)$$

Для вычисления вероятности необслуживания заявки (таймаут заявки), нужно рассчитать вероятность того, что время обслуживания превысит максимальное время обслуживания заявки, то есть рассчитать следующее значение:

$$P(T_{search,LSI}^{user} \geq T_{timeout}). \quad (30)$$

Время ожидания пользователя $T_{search,LSI}^{user}$ является суммой независимых случайной и детерминированной частей:

$$T_{search,LSI}^{user} = V + W_{search,LSI}^{coordinate} + \frac{Q + sNr}{v_{user}}, \quad (31)$$

где $W_{search,LSI}^{coordinate}$ равна $W_{search,q,LSI}^{execute} + T_{search,LSI}^{coordinate}$.

Детерминированная часть времени ожидания пользователя равна:

$$C^{user} = W_{search,q,LSI}^{execute} + C^{coordinate} + \frac{Q + sNr}{v_{user}}, \quad (32)$$

тогда случайная часть $T_{\text{search,LSI}}^{\text{user}}$ равна сумме двух независимых случайных величин:

$$T_{\text{search,LSI}}^{\text{user}} - C^{\text{user}} = V + Z, \quad (33)$$

где $V \sim \Gamma(2k_{\text{user}}, \theta_{\text{user}})$ и Z — максимум N независимых одинаково распределенных случайных величин с известной функцией распределения $F_Z(t)$.

Обозначим $\tau = T_{\text{timeout}} - C^{\text{user}}$. Тогда:

$$P(T_{\text{search,LSI}}^{\text{user}} \geq T_{\text{timeout}}) = P(V + Z \geq \tau). \quad (34)$$

Если $\tau \leq 0$, то таймаут наступает с вероятностью 1, так как даже детерминированная часть превышает допустимое время.

При $\tau > 0$ воспользуемся формулой свертки. Плотность распределения V известна в явном виде:

$$f_V(t) = t^{2k_{\text{user}}-1} \frac{e^{-t/\theta_{\text{user}}}}{\theta_{\text{user}}^{2k_{\text{user}}} \Gamma(2k_{\text{user}})}, t \geq 0. \quad (35)$$

Тогда вероятность таймаута рассчитывается через свертку:

$$P(V + Z \geq \tau) = \int_0^\tau f_V(t)[1 - F_Z(\tau - t)]dt + \int_\tau^\infty f_V(t)dt. \quad (36)$$

Первое слагаемое соответствует случаю, когда $V = t < \tau$, но Z компенсирует оставшееся время до таймаута. Второе слагаемое соответствует случаю, когда уже одной сетевой задержки пользователя достаточно для превышения таймаута.

Подставляя известные выражения:

$$\begin{aligned} P(T_{\text{search,LSI}}^{\text{user}} \geq T_{\text{timeout}}) &= \\ &= \int_0^\tau f_V(t) \left(1 - \left[\frac{\gamma(2k_{\text{cluster}}, \tau - t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^N \right) dt + \\ &\quad + 1 - \frac{\gamma(2k_{\text{user}}, \tau/\theta_{\text{user}})}{\Gamma(2k_{\text{user}})}. \end{aligned} \quad (37)$$

Данный интеграл можно вычислить численно методом Симпсона.

Среднее время обслуживания заявки равняется $M \left[T_{\text{search,LSI}}^{\text{user}} \right]$.

Среднее время ожидания заявки в очереди является суммарным временем нахождения заявки во всех очередях, то есть рассчитывается по формуле (38):

$$W_{\text{update,q,LSI}}^{\text{total}} = 2W_{\text{search,q,LSI}}^{\text{execute}}, \quad (38)$$

так как сначала заявки ожидает в очереди координатора за $W_{\text{search,q,LSI}}^{\text{execute}}$, потом еще по столько же параллельно на каждом исполнителе.

3.4 Поиск в глобальном индексе

Глобальные индексы устроены следующим образом:

- данные сегментированных таблиц распределены примерно равномерно среди наборов реплик, а принадлежность записи к набору реплик определяется значением ключа сегментирования;
- часть индекса находится на каждом наборе реплик, причем данные индекса поделены по вторичному ключу индексируемой таблицы.

Алгоритм поиска в кластере с такой индексной структурой выглядит следующим образом:

- 1) координатор принимает пользовательский запрос, рассчитывает на каком наборе реплик (набор реплик m) лежит искомый вторичный ключ;
- 2) координатор отправляет запрос на поиск всех записей с искомым вторичным ключом на исполнителя набора реплик m (исполнитель m);
- 3) на исполнителе m происходит поиск всех первичных ключей записей с искомым вторичным ключом в B^+ -дереве;
- 4) исполнитель m отправляет на все наборы реплик, содержащие найденные первичные ключи, запрос на поиск записей с этими ключами;
- 5) на каждом таком исполнителе происходит поиск записей по значению первичного ключа в B^+ -дереве;

- 6) каждый исполнитель отправляет найденные записи исполнителю m ;
- 7) исполнитель m объединяет данные с каждого исполнителя и отправляет найденные записи координатору;
- 8) координатор отправляет найденные записи пользователю.

На рисунке 3 представлена диаграмма последовательности описанного алгоритма. На ней изображены линии жизни следующих объектов:

- клиент — инициатор обращения к СУБД;
- координатор;
- исполнитель m — исполнитель, содержащий часть индекса с искомым вторичным ключом.
- исполнитель i — исполнитель набора реплик под номером i .




Рисунок 3 — UML Sequence диаграмма поиска в сегментированной таблице в СУБД Picodata с использованием ЛВИ

Исходя из этой диаграммы, можно оценить количество сетевых запросов при поиске с использованием ГВИ (NR_{search}^{GSI}) по следующей формуле:

$$6 \leq NR_{\text{search}}^{\text{GSI}} \leq 2k + 4, \quad (39)$$

где k — количество наборов реплик, среди которых расположенные все найденные первичные ключи.

В худшем случае, если много записей сегментированной таблицы имеют одинаковое значение искомого вторичного ключа ($K \rightarrow 1$), то произойдет опрос всего кластера. Прибавим к этому отправку запросов на координатор и на исполнителя m , и получим верхнюю границу; нижняя граница получается в случае, если все найденные первичные ключи лежат на одном наборе реплик.

Таким образом, в сравнении с поиском при использовании ЛВИ, описанном в пункте 3.3, получается, что при правильных входных данных можно добиться значительного сокращения сетевых запросов и ускорения исполнения запросов поиска. Помимо этого, уменьшится время использования ЦПУ по всему кластеру, ввиду того, что меньшее количество исполнителей будет производить локальный поиск.

Теорема 3.4.1 (*о времени ожидания исполнения запроса координатором при поиске в ГВИ*)

Время ожидания исполнения запроса координатором $W_{\text{search,GSI}}^{\text{coordinate}}$ является случайной величиной и рассчитывается по следующей формуле:

$$\begin{aligned} W_{\text{search,GSI}}^{\text{coordinate}} = & W_{\text{search,q,GSI}}^{\text{execute}} + t_{\text{request}}^{\text{FK-execute}} + \frac{P}{v_{\text{cluster}}} + \\ & + W_{\text{search,GSI}}^{\text{FK-execute}} + t_{\text{response}}^{\text{FK-execute}} + \frac{srN}{v_{\text{cluster}}}, \end{aligned} \quad (40)$$

где:

- $W_{\text{search,q,GSI}}^{\text{execute}}$ — время ожидания запроса в очереди исполнителя;
- $t_{\text{request}}^{\text{FK-execute}}$ и $t_{\text{response}}^{\text{FK-execute}}$ — времена задержки передачи запроса между координатором и исполнителем со вторичным ключом по сети;
- $W_{\text{search,GSI}}^{\text{FK-execute}}$ — время ожидания ответа от исполнителя со вторичным ключом;
- P — размер плана исполнения;
- v_{cluster} — скорость передачи данных между узлами СУБД;
- sN — количество записей с искомым вторичным ключом в кластере;
- r — размер одной записи.

Доказательство

Для начала рассмотрим время, которое проводится исключительно на самом координаторе.

Запрос сначала попадает в очередь исполнителя (так как координатор и исполнитель — это одно и то же приложение, то и очередь у них одна) и находится там $W_{\text{search,q,GSI}}^{\text{execute}}$ секунд. Далее он делегирует работу исполнителю с искомым вторичным ключом.

Отправление плана сопровождается сетевой задержкой, которая длится $t_{\text{request}}^{\text{FK-execute}}$, моделируемая как гамма-распределение $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$, аналогично лемме 3.2.1.

Положим, что план запроса весит P байтов, а скорость передачи данных между узлами кластера равна v_{cluster} байтов в секунду. Тогда весь план будет передан за P/v_{cluster} секунд.

На исполнителе время ожидания исполнения заявки, то есть время, проведенное в очереди в сумме с временем непосредственной обработки заявки обозначим как $W_{\text{search,GSI}}^{\text{execute}}$.

Результат работы каждого исполнителя отправляется координатору отдельным сетевым запросом с задержкой $t_{\text{request},i}^{\text{replicaset}}$, моделируемой гамма-распределением $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

Исходя из предположения, что данные распределены равномерно (в том числе по вторичным ключам) по наборам реплик, то на каждом исполнителе находится s , равное $\frac{D}{NK}$ искомым записей.

Положим, что одна запись весит r байтов, тогда передача данных с всего кластера занимает $\frac{srN}{v_{\text{cluster}}}$ секунд.

Итого, время ожидания исполнения запроса координатором $W_{\text{search,GSI}}^{\text{coordinate}}$ рассчитывается по следующей формуле:

$$\begin{aligned} W_{\text{search,GSI}}^{\text{coordinate}} = & W_{\text{search,q,GSI}}^{\text{execute}} + t_{\text{request}}^{\text{FK-execute}} + \frac{P}{v_{\text{cluster}}} + \\ & + W_{\text{search,GSI}}^{\text{FK-execute}} + t_{\text{response}}^{\text{FK-execute}} + \frac{srN}{v_{\text{cluster}}}, \end{aligned} \quad (41)$$

В правой части равенства присутствуют случайные величины, так что и левая часть является случайной величиной. $\square$

Теорема 3.4.2 (о времени ожидания ответа от исполнителя с искомым вторичным ключом)

Время ожидания ответа от исполнителя с искомым вторичным ключом $W_{\text{search,GSI}}^{\text{FK-execute}}$ является случайной величиной и рассчитывается по следующей формуле:

$$\begin{aligned} W_{\text{search,GSI}}^{\text{FK-execute}} = & W_{\text{search,q,GSI}}^{\text{execute}} + T_{\text{search,GSI}}^{\text{FK-execute}} + \max_{i=1..k} [T_{\text{search,GSI},i}^{\text{FK-execute}}] = \\ = & W_{\text{search,q,GSI}}^{\text{execute}} + T_{\text{search,GSI}}^{\text{FK-execute}} + \\ & + \max_{i=1..k} \left[t_{\text{request},i}^{\text{replicaset}} + \frac{P_i}{v_{\text{cluster}}} + W_{\text{search,GSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{s_i r}{v_{\text{cluster}}} \right], \end{aligned} \quad (42)$$

где:

- $W_{\text{search},q,\text{GSI}}^{\text{execute}}$ — время ожидания запроса в очереди исполнителя;
- $T_{\text{search},\text{GSI}}^{\text{FK-execute}}$ — время поиска первичных ключей в исполнителе со вторичными ключами;
- $T_{\text{search},\text{GSI},i}^{\text{FK-execute}}$ — время ожидания ответа от исполнителя под номером i ;
- $t_{\text{request},i}^{\text{replicaset}}$ и $t_{\text{response},i}^{\text{replicaset}}$ — времена задержки передачи запроса между координатором и исполнителем под номером i по сети;
- P_i — размер плана исполнения для исполнителя под номером i ;
- v_{cluster} — скорость передачи данных между узлами СУБД;
- $W_{\text{search},\text{GSI}}^{\text{execute}}$ — время ожидания обработки запроса исполнителем;
- s — количество записей с искомым вторичным ключом на наборе реплик;
- r — размер одной записи;
- $k \leq N$ — количество наборов реплик, на которых располагаются первичные ключи.

Доказательство

Для начала рассмотрим время, которое проводится исключительно на самом исполнителе со вторичными ключами.

Запрос сначала попадает в очередь исполнителя и находится там $W_{\text{search},q,\text{GSI}}^{\text{execute}}$ секунд. После этого происходит поиск первичных ключей в B+*-дереве за $T_{\text{search},\text{GSI}}^{\text{FK-execute}}$.

Итого, на координаторе заявка обрабатывается $W_{\text{search},q,\text{LSI}}^{\text{execute}} + T_{\text{search},\text{GSI}}^{\text{FK-execute}}$ секунд, далее он делегирует работу исполнителям.

Рассмотрим сколько времени занимает обработка поиска на исполнителях.

Каждому исполнителю составляется отдельный план запроса P_i . Он отправляется каждому исполнителю по сети, которых всего k штук — первичных ключей может быть меньше чем наборов реплик в кластере, и несколько первичных ключей может быть на одном наборе реплик. Мы будем моделировать k как случайную величину.

Каждое отправление плана сопровождается сетевой задержкой, которая длится $t_{\text{request},i}^{\text{replicaset}}$, моделируемая как гамма-распределение $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

Положим, что план запроса весит P_i байтов, а скорость передачи данных между узлами кластера равна v_{cluster} байтов в секунду. Тогда весь план будет передан через P/v_{cluster} секунд.

На исполнителе время ожидания исполнения заявки, то есть время, проведенное в очереди в сумме с временем непосредственной обработки заявки обозначим как $W_{\text{search,GSI}}^{\text{execute}}$.

Результат работы каждого исполнителя отправляется исполнителю со вторичными ключами отдельным сетевым запросом с задержкой $t_{\text{request},i}^{\text{replicaset}}$, моделируемой гамма-распределением $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

На каждом исполнителе находится s_i записей. Одна запись весит r байтов, тогда передача данных с одного исполнителя занимает $\frac{s_i r}{v_{\text{cluster}}}$ секунд.

Итого, время, которое занимает прием и обработка плана исполнения на одном исполнителе является следующей суммой:

$$t_{\text{request},i}^{\text{replicaset}} + \frac{P_i}{v_{\text{cluster}}} + W_{\text{search,GSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{s_i r}{v_{\text{cluster}}}, \quad (43)$$

которую мы обозначим $T_{\text{search,GSI},i}^{\text{FK-execute}}$.

Исполнитель со вторичным ключом должен дожидаться ответа от всех исполнителей, чтобы вернуть объединенный результат пользователю, так что время ожидания исполнителей равно времени ожидания самого долгого исполнителя, что является максимумом среди всех $T_{\text{search,GSI},i}^{\text{FK-execute}}$.

Итого, время ожидания исполнения запроса координатором $W_{\text{search,GSI}}^{\text{FK-execute}}$ рассчитывается по следующей формуле:

$$\begin{aligned} W_{\text{search,GSI}}^{\text{FK-execute}} &= W_{\text{search,q,GSI}}^{\text{execute}} + T_{\text{search,GSI}}^{\text{FK-execute}} + \max_{i=1..k} [T_{\text{search,GSI},i}^{\text{FK-execute}}] = \\ &= W_{\text{search,q,GSI}}^{\text{execute}} + T_{\text{search,GSI}}^{\text{FK-execute}} + \\ &+ \max_{i=1..k} \left[t_{\text{request},i}^{\text{replicaset}} + \frac{P_i}{v_{\text{cluster}}} + W_{\text{search,GSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{s_i r}{v_{\text{cluster}}} \right], \end{aligned} \quad (44)$$

В правой части равенства присутствуют случайные величины, так что и левая часть является случайной величиной. $\square$

Так как в итоге один пользовательский запрос на превращается в k запросов для исполнителей, то интенсивность потока, поступающих в исполнителей рассчитывается по следующей формуле:

$$\lambda_{\text{search,GSI}}^{\text{sub}} = \frac{\lambda_{\text{search,GSI}} k}{N}. \quad (45)$$

Рассчитаем чему равно $T_{\text{search,GSI}}^{\text{execute}}$. Поиск n вразнобой-идущих ключей занимает в n раз дольше времени, чем поиск одного ключа, то есть совершается $n \log_m d$ переходов по указателю и $n \log_m d \log_2(2m - 1)$ операций сравнения.

Тогда, $T_{\text{search,GSI}}^{\text{execute}}$ рассчитывается по следующей формуле:

$$T_{\text{search,GSI}}^{\text{execute}} = \frac{n \log_m d \log_2(2m - 1)}{f_{\text{cpu}}} + \frac{n \log_m d}{f_{\text{mem}}} \quad (46)$$

и является детерминированной величиной.

Отсюда нагрузка на исполнителя вычисляется по следующей формуле:

$$\rho_{\text{search,GSI}}^{\text{executor}} = T_{\text{search,GSI}}^{\text{execute}} \lambda_{\text{search,GSI}}^{\text{sub}} \quad (47)$$

Для вычисления времени обслуживания заявки и времени ожидания в очереди воспользуемся формулой Полячека-Хинчина:

$$\begin{aligned} L_{\text{search,GSI}}^{\text{execute}} &= \rho_{\text{search,GSI}}^{\text{executor}} + \frac{\rho_{\text{search,GSI}}^{\text{executor}^2} + \lambda_{\text{search,GSI}}^{\text{sub}} D[T_{\text{search,GSI}}^{\text{execute}}]}{2(1 - \rho_{\text{search,GSI}}^{\text{executor}})} = \\ &= \rho_{\text{search,GSI}}^{\text{executor}} + \frac{\rho_{\text{search,GSI}}^{\text{executor}^2}}{2(1 - \rho_{\text{search,GSI}}^{\text{executor}})}, \end{aligned} \quad (48)$$

и среднее время ожидания зявки в исполнителе в соответствии с законом Литтла:

$$W_{\text{search,GSI}}^{\text{execute}} = \frac{L_{\text{search,GSI}}^{\text{execute}}}{\lambda_{\text{search}}} = T_{\text{search,GSI}}^{\text{execute}} + \frac{\rho_{\text{search,GSI}}^{\text{executor}} T_{\text{search,GSI}}^{\text{execute}}}{2(1 - \rho_{\text{search,GSI}}^{\text{executor}})}. \quad (49)$$

Время, проведенное в очереди равно времени проведенному в системе без времени обслуживания заявки, тогда:

$$W_{\text{search,q,GSI}}^{\text{execute}} = W_{\text{search,GSI}}^{\text{execute}} - T_{\text{search,GSI}}^{\text{execute}} = \frac{\rho_{\text{search,GSI}}^{\text{executor}} T_{\text{search,GSI}}^{\text{execute}}}{2(1 - \rho_{\text{search,GSI}}^{\text{executor}})}. \quad (50)$$

Оценим время работы исполнителя со вторичным ключом, связанное с одним исполнителем:

$$T_{\text{search,GSI},i}^{\text{FK-execute}} = t_{\text{request},i}^{\text{replicaset}} + \frac{P_i}{v_{\text{cluster}}} + W_{\text{search,GSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{s_i r}{v_{\text{cluster}}}. \quad (51)$$

Для удобства, возьмем средние значения для плана исполнения и найденного количества данных, то есть:

$$P_i = P_{\text{avg}}, \quad (52)$$

$$s_i = s, \quad (53)$$

тогда, формула (51) примет вид:

$$T_{\text{search,GSI},i}^{\text{FK-execute}} = t_{\text{request},i}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{search,GSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{sr}{v_{\text{cluster}}}. \quad (54)$$

Случайную часть $T_{\text{search,GSI},i}^{\text{FK-execute}}$ обозначим U , а детерминированную — $C^{\text{FK-execute}}$.

$$C^{\text{FK-execute}} = W_{\text{search,GSI}}^{\text{execute}} + \frac{P_{\text{avg}} + sr}{v_{\text{cluster}}}, \quad (55)$$

$$U = T_{\text{search,GSI},i}^{\text{FK-execute}} - C^{\text{FK-execute}} \sim \Gamma(2k_{\text{cluster}}, \theta_{\text{cluster}}). \quad (56)$$

Следовательно функция распределения равна:

$$F_U(t) = P(U \leq t) = \frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})}. \quad (57)$$

Дальнейшие рассуждения по поводу $T_{\text{search,GSI}}^{\text{FK-execute}}$ аналогичны рассуждениям для $T_{\text{search,LSI}}^{\text{coordinate}}$, за исключением добавления времени поиска в B^{+} -дереве и взятии максимума не из N значений, а из k .

Случайную часть $T_{\text{search,GSI}}^{\text{FK-execute}}$ обозначим V , неслучайную часть обозначим $C_{\text{full}}^{\text{FK-execute}}$. Максимум среди одинаковых неслучайных величин $C^{\text{FK-execute}}$ равен самому себе:

$$C_{\text{full}}^{\text{FK-execute}} = C^{\text{FK-execute}} + T_{\text{search,GSI}}^{\text{FK-execute}} \quad (58)$$

$$V = T_{\text{search,GSI}}^{\text{FK-execute}} - C_{\text{full}}^{\text{FK-execute}} \quad (59)$$

значит, функция распределения V равна:

$$F_V(t) = [F_U(t)]^k = \left[\frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^k, \quad (60)$$

что позволяет нам численно найти моменты $T_{\text{search,GSI}}^{\text{FK-execute}}$ через функцию выживания [15]:

$$M[V] = \int_0^\infty \left(1 - \left[\frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^k \right) dt, \quad (61)$$

$$M[V^2] = \int_0^\infty 2t \left(1 - \left[\frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^k \right) dt, \quad (62)$$

$$M[T_{\text{search,GSI}}^{\text{FK-execute}}] = M[V] + C_{\text{full}}^{\text{FK-execute}}, \quad (63)$$

$$D[T_{\text{search,GSI}}^{\text{FK-execute}}] = D[V] = M[V^2] - (M[V])^2. \quad (64)$$

В свою очередь:

$$M[W_{\text{search,GSI}}^{\text{FK-execute}}] = W_{\text{search,q,GSI}}^{\text{execute}} + M[T_{\text{search,GSI}}^{\text{FK-execute}}], \quad (65)$$

$$D[W_{\text{search,GSI}}^{\text{FK-execute}}] = D[T_{\text{search,GSI}}^{\text{FK-execute}}] \quad (66)$$

Время задержек в $T_{\text{search,GSI}}^{\text{coordinate}}$, обозначим за W , тогда:

$$W = t_{\text{request}}^{\text{FK-execute}} + t_{\text{response}}^{\text{FK-execute}} \sim \Gamma(2k_{\text{cluster}}, \theta_{\text{cluster}}), \quad (67)$$

из чего можно найти математическое ожидание и дисперсию времени работы координатора:

$$\begin{aligned} M[T_{\text{search,GSI}}^{\text{coordinate}}] &= M[W] + M[W_{\text{search,GSI}}^{\text{FK-execute}}] + \frac{P_{\text{avg}} + srN}{v_{\text{user}}} = \\ &= k_{\text{cluster}}\theta_{\text{cluster}} + M[W_{\text{search,GSI}}^{\text{FK-execute}}] + \frac{P_{\text{avg}} + srN}{v_{\text{user}}}, \end{aligned} \quad (68)$$

$$\begin{aligned} D[T_{\text{search,GSI}}^{\text{coordinate}}] &= D[W] + D[W_{\text{search,GSI}}^{\text{FK-execute}}] = \\ &= k_{\text{cluster}}\theta_{\text{cluster}}^2 + D[W_{\text{search,LSI}}^{\text{coordinate}}]. \end{aligned} \quad (69)$$

Время обработки заявки координатором равно:

$$W_{\text{search,GSI}}^{\text{coordinate}} = W_{\text{search,q,GSI}}^{\text{execute}} + T_{\text{search,GSI}}^{\text{coordinate}} \quad (70)$$

Наконец, можно найти среднее и дисперсию времени ожидания пользователем. Для этого обозначим за X время сетевых задержек:

$$X = t_{\text{request}}^{\text{user}} + t_{\text{response}}^{\text{user}} \sim \Gamma(2k_{\text{user}}, \theta_{\text{user}}), \quad (71)$$

следовательно:

$$\begin{aligned} M[T_{\text{search,GSI}}^{\text{user}}] &= M[X] + M[W_{\text{search,GSI}}^{\text{coordinate}}] + \frac{P + srN}{v_{\text{cluster}}} = \\ &= k_{\text{user}}\theta_{\text{user}} + M[W_{\text{search,GSI}}^{\text{coordinate}}] + \frac{P + srN}{v_{\text{cluster}}}, \end{aligned} \quad (72)$$

$$\begin{aligned} D[T_{\text{search,GSI}}^{\text{user}}] &= D[X] + D[W_{\text{search,GSI}}^{\text{coordinate}}] = \\ &= k_{\text{user}}\theta_{\text{user}}^2 + D[W_{\text{search,GSI}}^{\text{coordinate}}]. \end{aligned} \quad (73)$$

3.4.1 Расчет показателей эффективности

Максимальное количество запросов в секунду достигается при максимальной загрузке системы. Так как мы договорились, что составление плана исполнения координатором не учитывается в модели, на него можно подать бесконечную нагрузку. Тогда единственным ограничивающим фактором системы является время обработки заявки исполнителем $T_{\text{search,LSI}}^{\text{execute}}$.

Для устойчивости системы, загрузка системы $\rho_{\text{search,GSI}}^{\text{executor}}$ должна не превышать единицу. По определению, загрузка системы рассчитывается по формуле (47), значит максимальная нагрузка системы рассчитывается по следующей формуле:

$$\lambda_{\text{search,GSI}}^{\text{sub,max}} = \frac{1}{T_{\text{search,GSI}}^{\text{execute}}}, \quad (74)$$

а по формуле (45), верно, что:

$$\lambda_{\text{search,GSI}}^{\text{max}} = \frac{\lambda_{\text{search,GSI}}^{\text{sub,max}} N}{k} = \frac{N}{T_{\text{search,GSI}}^{\text{execute}} k}. \quad (75)$$

Для вычисления вероятности таймаута заявки необходимо найти $P(T_{\text{search,GSI}}^{\text{user}} \geq T_{\text{timeout}})$.

Время ожидания пользователя $T_{\text{search,GSI}}^{\text{user}}$ является суммой независимых случайных и детерминированных частей. Выделим полную детерминированную часть:

$$\begin{aligned} C^{\text{user}} = & W_{\text{search,q,GSI}}^{\text{execute}} + \frac{P + srN}{v_{\text{cluster}}} + \\ & + W_{\text{search,q,GSI}}^{\text{execute}} + C_{\text{full}}^{\text{FK-execute}} + \frac{P_{\text{avg}} + srN}{v_{\text{user}}}. \end{aligned} \quad (76)$$

Случайная часть $T_{\text{search,GSI}}^{\text{user}}$ равна сумме трёх независимых случайных величин:

$$T_{\text{search,GSI}}^{\text{user}} - C^{\text{user}} = X + W + V, \quad (77)$$

где:

- $X \sim \Gamma(2k_{\text{user}}, \theta_{\text{user}})$ – сетевые задержки между пользователем и координатором;
- $W \sim \Gamma(2k_{\text{cluster}}, \theta_{\text{cluster}})$ – сетевые задержки между координатором и исполнителем со вторичным ключом;
- V – максимум k независимых одинаково распределённых случайных величин с функцией распределения $F_V(t)$.

Обозначим $\tau = T_{\text{timeout}} - C^{\text{user}}$. Тогда:

$$P(T_{\text{search,GSI}}^{\text{user}} \geq T_{\text{timeout}}) = P(X + W + V \geq \tau). \quad (78)$$

При $\tau > 0$ заметим, что сумма $X + W$ двух независимых гамма-распределённых величин с одинаковым параметром масштаба не сводится к гамма-распределению, так как параметры масштаба различны ($\theta_{\text{user}} \neq \theta_{\text{cluster}}$ в общем случае). Поэтому воспользуемся последовательной свёрткой.

Сначала найдем распределение суммы $X + W$. Плотности обеих величин известны:

$$f_X(t) = t^{2k_{\text{user}}-1} \frac{e^{-t/\theta_{\text{user}}}}{\theta_{\text{user}}^{2k_{\text{user}}} \Gamma(2k_{\text{user}})}, t \geq 0, \quad (79)$$

$$f_W(t) = t^{2k_{\text{cluster}}-1} \frac{e^{-t/\theta_{\text{cluster}}}}{\theta_{\text{cluster}}^{2k_{\text{cluster}}} \Gamma(2k_{\text{cluster}})}, t \geq 0. \quad (80)$$

Плотность их суммы $X = X + W$ вычисляется свёрткой:

$$f_X(t) = \int_0^t f_X(u) f_W(t-u) du, t \geq 0. \quad (81)$$

Теперь вероятность таймаута выражается через свёртку X и V :

$$P(X + V \geq \tau) = \int_0^\tau f_X(t) [1 - F_V(\tau - t)] dt + \int_\tau^\infty f_X(t) dt. \quad (82)$$

Подставляя выражение для F_V :

$$P(T_{\text{search,GSI}}^{\text{user}} \geq T_{\text{timeout}}) = \int_0^\tau f_X(t) \left(1 - \left[\frac{\gamma(2k_{\text{cluster}}, \tau - t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right]^k \right) dt + 1 - F_X(\tau), \quad (83)$$

где $F_X(\tau) = \int_0^\tau f_X(t) dt$ — функция распределения суммы X .

В частном случае $\theta_{\text{user}} = \theta_{\text{cluster}} = \theta$ сумма $X + W$ имеет гамма-распределение $\Gamma(2k_{\text{user}} + 2k_{\text{cluster}}, \theta)$, и плотность f_X записывается в замкнутом виде, что упрощает численное интегрирование.

Все интегралы можно вычислить численно методом Симпсона. При этом внутренняя свёртка для $f_{X(t)}$ также вычисляется численно в каждой точке, что приводит к двойному численному интегрированию.

Среднее время обслуживания заявки равняется $M\left[T_{\text{search,GSI}}^{\text{user}}\right]$.

Среднее время ожидания заявки в очереди является суммарным временем нахождения заявки во всех очередях, то есть рассчитывается по формуле (84):

$$W_{\text{search,q,GSI}}^{\text{total}} = 3W_{\text{search,q,GSI}}^{\text{execute}}, \quad (84)$$

так как сначала заявки ожидает в очереди координатора за $W_{\text{search,q,LSI}}^{\text{execute}}$, потом еще столько же в исполнителе с искомым вторичным ключом и еще по столько же параллельно на каждом исполнителе.

3.5 Обновление в локальном индексе

Алгоритм записи в кластере с такой индексной структурой выглядит следующим образом:

- 1) координатор принимает пользовательский запрос, рассчитывает бакет обновляемой записи и отправляет план исполнения соответствующему исполнителю;
- 2) исполнитель добавляет информацию об обновлении таблицы в журнал упреждающей записи, обновляет B+*-дерево индекса первичного ключа и обновляет B+*-дерево вторичного индекса;
- 3) исполнитель отправляет подтверждение записи координатору;
- 4) координатор отправляет подтверждение записи пользователю.

На рисунке 4 представлена диаграмма последовательности обновления ЛВИ. На ней изображены линии жизни следующих объектов:

- клиент — инициатор обращения к СУБД Picodata;
- координатор;
- исполнитель m — исполнитель набора реплик на котором лежит первичный ключ записи.




Рисунок 4 – UML Sequence диаграмма построения ЛВИ в СУБД Picodata при вставке в шардированную таблицу

Количество сетевых запросов при обновлении ЛВИ (NR_{update}^{LSI}) равно 4.

Теорема 3.5.1 (о времени ожидания исполнения запроса координатором при обновлении ЛВИ)

Время ожидания исполнения запроса координатором $W_{update,LSI}^{coordinate}$ является случайной величиной и рассчитывается по следующей формуле:

$$\begin{aligned}
 W_{update,LSI}^{coordinate} &= W_{update,q,LSI}^{execute} + T_{update,LSI}^{coordinate} = \\
 &= W_{update,q,LSI}^{execute} + t_{request}^{replicaset} + \frac{P}{v_{cluster}} + W_{update,LSI}^{execute} + t_{response}^{replicaset},
 \end{aligned} \tag{85}$$

где:

- $W_{\text{update,q,LSI}}^{\text{execute}}$ — время ожидания запроса в очереди исполнителя;
- $T_{\text{update,LSI}}^{\text{coordinate}}$ — время ожидания ответа от исполнителя;
- $t_{\text{request}}^{\text{replicaset}}$ и $t_{\text{response}}^{\text{replicaset}}$ — времена задержки передачи запроса между координатором и исполнителем по сети;
- P — размер плана исполнения;
- v_{cluster} — скорость передачи данных между узлами СУБД;
- $W_{\text{update,LSI}}^{\text{execute}}$ — время ожидания обработки запроса исполнителем;
- s — количество записей с искомым вторичным ключом на наборе реплик;
- r — размер одной записи.

Доказательство

Запрос сначала попадает в очередь исполнителя и находится там $W_{\text{search,q,LSI}}^{\text{execute}}$ секунд.

Составленный план запроса отправляется одному исполнителю по сети.

Отправление плана сопровождается сетевой задержкой, которая длится $t_{\text{request}}^{\text{replicaset}}$, моделируемая как гамма-распределение $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

Положим, что план запроса весит P байтов, а скорость передачи данных между узлами кластера равна v_{cluster} байтов в секунду. Тогда весь план будет передан через P/v_{cluster} секунд.

На исполнителе время ожидания исполнения заявки, то есть время, проведенное в очереди в сумме с временем непосредственной обработки заявки обозначим как $W_{\text{search,LSI}}^{\text{execute}}$.

Результат работы исполнителя отправляется координатору отдельным сетевым запросом с задержкой $t_{\text{request},i}^{\text{replicaset}}$, моделируемой гамма-распределением $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

Сам результат весит 16 байтов — это подтверждение записи, время его передачи мало, поэтому не учитывается.

Итого, время ожидания исполнения запроса координатора $W_{\text{update,LSI}}^{\text{coordinate}}$ рассчитывается по следующей формуле:

$$\begin{aligned}
W_{\text{update,LSI}}^{\text{coordinate}} &= W_{\text{update,q,LSI}}^{\text{execute}} + T_{\text{update,LSI}}^{\text{coordinate}} = \\
&= W_{\text{update,q,LSI}}^{\text{execute}} + t_{\text{request}}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{update,LSI}}^{\text{execute}} + t_{\text{response}}^{\text{replicaset}},
\end{aligned} \tag{86}$$

В правой части равенства присутствуют случайные величины, так что и левая часть является случайной величиной. $\square$

Получается, каждая заявка на обновление порождает ровно одну подзадачу для одного исполнителя. Поток запросов координатора $\lambda_{\text{update,LSI}}$ распределяется равномерно на исполнителей:

$$\lambda_{\text{update,LSI}}^{\text{sub}} = \frac{\lambda_{\text{update}}}{N}. \tag{87}$$

Рассмотрим чему равно время обработки заявки исполнителем $W_{\text{update,LSI}}^{\text{execute}}$.

Обновление начинается с записи в журнал упреждающей записи, которое занимает константное время T_{WAL} . После этого происходит поиск позиции ключа в B⁺-дереве для обновления, на что тратится $\log_m d \log_2(2m - 1)$ операций сравнения ключей и $\log_m d$ переходов по указателям.

После поиска происходит обновление дерева, например вставка нового элемента. В лучшем случае, когда лист не заполнен до конца, вставка происходит за одну операцию записи в запоминающее устройство, в худшем — все узлы в пути до листа (включая сам лист) нужно разделить на два. Для простоты модели, сошлемся на статью [16], в которой доказано, что средняя заполненность B⁺-дерева, а значит и средняя заполненность каждого узла равна $P_{\text{full}} = 0.81$, где 0 — узел пуст, 1 — узел полон.

Получается, что в среднем остается $(2m - 1)(1 - 0.81) = 0.19(2m - 1)$ вставок перед переполнением узла, соответственно вероятность переполнения на конкретной вставке равна $(0.19(2m - 1))^{-1} \approx \frac{5.26}{2m-1}$. Разделение узла происходит за 3 операции записи — перезапись разделенного узла, запись нового братского узла и перезапись родительского узла. Случай каскадного разделения родительских узлов возможен, но маловероятен (вероятность этого события уменьшается с каждым родителем экспоненциально), так что он не учтен.

Итого, время решения подзадачи обновления равно:

$$T_{\text{update,LSI}}^{\text{execute}} = T_{\text{WAL}} + 2 \left(\frac{\log_m d \log_2(2m-1)}{f_{\text{cpu}}} + \frac{\log_m d + 3 \cdot \frac{5.26}{2m-1}}{f_{\text{mem}}} \right) \quad (88)$$

Это также детерминированная величина. Вычислим время ожидания обработки заявки $W_{\text{update,LSI}}^{\text{execute}}$ с помощью формулы Полячека-Хинчина:

$$\rho_{\text{update,LSI}}^{\text{executor}} = \lambda_{\text{update,LSI}}^{\text{sub}} \cdot T_{\text{update,LSI}}^{\text{execute}} \quad (89)$$

$$\begin{aligned} L_{\text{update,LSI}}^{\text{execute}} &= \rho_{\text{update,LSI}}^{\text{executor}} + \frac{\rho_{\text{update,LSI}}^{\text{executor}^2} + \lambda_{\text{update,LSI}}^{\text{sub}} D[T_{\text{update,LSI}}^{\text{execute}}]}{2(1 - \rho_{\text{update,LSI}}^{\text{executor}})} = \\ &= \rho_{\text{update,LSI}}^{\text{executor}} + \frac{\rho_{\text{update,LSI}}^{\text{executor}^2}}{2(1 - \rho_{\text{update,LSI}}^{\text{executor}})}, \end{aligned} \quad (90)$$

и среднее время ожидания заявки в исполнителе в соответствии с законом Литтла:

$$W_{\text{update,LSI}}^{\text{execute}} = \frac{L_{\text{update,LSI}}^{\text{execute}}}{\lambda_{\text{update}}} = T_{\text{update,LSI}}^{\text{execute}} + \frac{\rho_{\text{update,LSI}}^{\text{executor}} T_{\text{update,LSI}}^{\text{execute}}}{2(1 - \rho_{\text{update,LSI}}^{\text{executor}})}. \quad (91)$$

Время, проведенное в очереди равно времени проведенному в системе без времени обслуживания заявки, тогда:

$$W_{\text{update,q,LSI}}^{\text{execute}} = W_{\text{update,LSI}}^{\text{execute}} - T_{\text{update,LSI}}^{\text{execute}} = \frac{\rho_{\text{update,LSI}}^{\text{executor}} T_{\text{update,LSI}}^{\text{execute}}}{2(1 - \rho_{\text{update,LSI}}^{\text{executor}})}. \quad (92)$$

Рассчитаем время работы координатора:

$$T_{\text{update,LSI}}^{\text{coordinate}} = t_{\text{request},i}^{\text{replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{search,LSI}}^{\text{execute}} + t_{\text{response},i}^{\text{replicaset}} + \frac{sr}{v_{\text{cluster}}}. \quad (93)$$

Только времена сетевой задержки — случайные величины, остальные — скалярные, так что, согласно свойствам гамма-распределения, время работы координатора — случайная величина, имеющая сдвинутое

гамма-распределение. Случайную часть $T_{\text{update,LSI}}^{\text{coordinate}}$ обозначим Y , а детерминированную — $C^{\text{coordinate}}$.

$$C^{\text{coordinate}} = W_{\text{update,LSI}}^{\text{execute}} + \frac{P + sr}{v_{\text{cluster}}}, \quad (94)$$

$$Y = T_{\text{update,LSI}}^{\text{coordinate}} - C^{\text{coordinate}} \sim \Gamma(2k_{\text{cluster}}, \theta_{\text{cluster}}). \quad (95)$$

Следовательно функция распределения равна:

$$F_Y(t) = P(Y \leq t) = \frac{\gamma(2k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})}. \quad (96)$$

Времена сетевых задержек во времени ожидания пользователя $T_{\text{update,LSI}}^{\text{user}}$ обозначим X , тогда:

$$X = t_{\text{request}}^{\text{user}} + t_{\text{response}}^{\text{user}} \sim \Gamma(2k_{\text{user}}, \theta_{\text{user}}), \quad (97)$$

следовательно:

$$\begin{aligned} M[T_{\text{update,LSI}}^{\text{user}}] &= M[X] + M[W_{\text{update,LSI}}^{\text{coordinate}}] = \\ &= k_{\text{user}} \theta_{\text{user}} + M[W_{\text{update,LSI}}^{\text{coordinate}}], \end{aligned} \quad (98)$$

$$\begin{aligned} D[T_{\text{update,LSI}}^{\text{user}}] &= D[Y] + D[W_{\text{update,LSI}}^{\text{coordinate}}] = \\ &= k_{\text{user}} \theta_{\text{user}}^2 + D[W_{\text{update,LSI}}^{\text{coordinate}}]. \end{aligned} \quad (99)$$

3.6 Расчет параметров эффективности

Максимальное количество запросов в секунду достигается при максимальной загрузке системы. Так как мы договорились, что по факту работа на координаторе не учитывается в модели, то на него можно подать бесконечную нагрузку. Тогда единственным ограничивающим фактором системы является время обработки заявки исполнителем $T_{\text{update,LSI}}^{\text{execute}}$.

Для устойчивости системы, нагрузка системы $\rho_{\text{update,LSI}}^{\text{executor}}$ должна не превышать единицу. По определению, нагрузка системы рассчитывается по формуле (89), значит максимальная нагрузка системы рассчитывается по следующей формуле:

$$\lambda_{\text{update,LSI}}^{\text{sub,max}} = \frac{1}{T_{\text{update,LSI}}^{\text{execute}}}, \quad (100)$$

а по формуле (87), верно, что:

$$\lambda_{\text{update,LSI}}^{\text{max}} = \lambda_{\text{update,LSI}}^{\text{sub,max}} N = \frac{N}{T_{\text{update,LSI}}^{\text{execute}}}. \quad (101)$$

Найдем вероятность того, что время ожидания пользователем завершения операции обновления $T_{\text{update,LSI}}^{\text{user}}$ превысит заданный лимит T_{timeout} , то есть вычислим $P(T_{\text{update,LSI}}^{\text{user}} \geq T_{\text{timeout}})$.

Время ожидания пользователя складывается из детерминированной и случайной частей:

$$T_{\text{update,LSI}}^{\text{user}} = W_{\text{update,q,LSI}}^{\text{execute}} + C^{\text{coordinate}} + Y + X, \quad (102)$$

где

- $X \sim \text{Gamma}(2k_{\text{user}}, \theta_{\text{user}})$ – суммарная задержка сети между пользователем и координатором (запрос + ответ);
- $Y \sim \text{Gamma}(2k_{\text{cluster}}, \theta_{\text{cluster}})$ – суммарная задержка сети между координатором и исполнителем;
- детерминированная составляющая $C^{\text{user}} = W_{\text{update,q,LSI}}^{\text{execute}} + C^{\text{coordinate}}$.

Результат подтверждения записи пренебрежимо мал, поэтому не учитывается.

Определим $\tau = T_{\text{timeout}} - C^{\text{user}}$. При $\tau > 0$ воспользуемся формулой свёртки для суммы двух независимых случайных величин. Обозначим $X = X$, $Y = Y$. Плотность X известна:

$$f_{X(t)} = \frac{t^{2k_{\text{user}}-1} e^{-t/\theta_{\text{user}}}}{\theta_{\text{user}}^{2k_{\text{user}}} \Gamma(2k_{\text{user}})}, t \geq 0. \quad (103)$$

Функция распределения Y выражается через регуляризованную нижнюю неполную гамма-функцию:

$$F_{Y(y)} = P(Y \leq y) = \frac{\gamma(2k_{\text{cluster}}, y/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})}. \quad (104)$$

Вероятность таймаута:

$$\begin{aligned}
P(T_{\text{update,LSI}}^{\text{user}} \geq T_{\text{timeout}}) &= P(X + Y \geq \tau) = \\
&= \int_0^\tau f_{X(t)} (1 - F_{Y(\tau-t)}) dt + \int_\tau^\infty f_{X(t)} dt.
\end{aligned} \tag{105}$$

Второе слагаемое — вероятность того, что одна лишь пользовательская задержка уже превышает τ , и равно $1 - P(2k_{\text{user}}, \tau/\theta_{\text{user}})$, где $P(a, x) = \gamma(a, x)/\Gamma(a)$. Первое слагаемое учитывает случаи, когда $X = t < \tau$, но Y компенсирует оставшееся время.

Подставляя явные выражения, получаем окончательную формулу:

$$\begin{aligned}
P(T_{\text{update,LSI}}^{\text{user}} \geq T_{\text{timeout}}) &= \\
&= \int_0^\tau \frac{t^{2k_{\text{user}}-1} e^{-t/\theta_{\text{user}}}}{\theta_{\text{user}}^{2k_{\text{user}}} \Gamma(2k_{\text{user}})} \left(1 - \frac{\gamma(2k_{\text{cluster}}, (\tau-t)/\theta_{\text{cluster}})}{\Gamma(2k_{\text{cluster}})} \right) dt + \\
&\quad + 1 - \frac{\gamma(2k_{\text{user}}, \tau/\theta_{\text{user}})}{\Gamma(2k_{\text{user}})}.
\end{aligned} \tag{106}$$

Все величины, входящие в формулу, определены в предыдущих разделах. Интеграл вычисляется численно методом Симпсона, так как замкнутая форма для свертки гамма-распределений с разными параметрами масштаба отсутствует. В частном случае $\theta_{\text{user}} = \theta_{\text{cluster}}$ сумма $X + Y$ имеет гамма-распределение $\Gamma(2k_{\text{user}} + 2k_{\text{cluster}}, \theta_{\text{user}})$, и вероятность можно вычислить аналитически через регуляризованную гамма-функцию.

Среднее время обслуживания заявки равняется $M[T_{\text{update,LSI}}^{\text{user}}]$.

Среднее время ожидания заявки в очереди является суммарным временем нахождения заявки во всех очередях, то есть рассчитывается по формуле (107):

$$W_{\text{update,q,LSI}}^{\text{total}} = 2W_{\text{update,q,LSI}}^{\text{execute}}, \tag{107}$$

так как сначала заявки ожидает в очереди координатора за $W_{\text{update,q,LSI}}^{\text{execute}}$, потом еще столько же в исполнителе.

3.7 Обновление в глобальном индексе

Алгоритм записи в кластере с такой индексной структурой выглядит следующим образом:

- 1) координатор принимает пользовательский запрос, рассчитывает бакет обновляемой записи и отправляет план исполнения исполнителю с первичным ключом;
- 2) исполнитель с первичным ключом добавляет информацию об обновлении таблицы в журнал упреждающей записи, обновляет $B+^*$ -дерево индекса первичного ключа b отправляет подтверждение записи координатору;
- 3) координатор рассчитывает бакет вторичного ключа и отправляет план исполнения исполнителю со вторичным ключом;
- 4) исполнитель со вторичным ключом добавляет информацию об обновлении таблицы в журнал упреждающей записи, обновляет $B+^*$ -дерево ГВИ;
- 5) исполнитель со вторичным ключом возвращает координатору подтверждение записи;
- 6) координатор отправляет подтверждение записи пользователю.

На рисунке 5 представлена диаграмма последовательности обновления ГВИ. На ней изображены линии жизни следующих объектов:

- клиент — инициатор обращения к СУБД Picodata;
- координатор;
- исполнитель m — исполнитель набора реплик на котором лежит первичный ключ записи.
- исполнитель k — исполнитель набора реплик на котором лежит вторичный ключ записи.




Рисунок 5 — UML Sequence диаграмма построения ГВИ в СУБД Picodata при вставке в шардированную таблицу

Количество сетевых запросов при обновлении ГВИ (NR_{update}^{GSI}) равно 4.

Теорема 3.7.1 (о времени ожидания исполнения запроса координатором при обновлении ГВИ)

Время ожидания исполнения запроса координатором $W_{update,GSI}^{coordinate}$ является случайной величиной и рассчитывается по следующей формуле:

$$\begin{aligned}
 W_{update,GSI}^{coordinate} = & W_{update,q,GSI}^{execute} + T_{update,GSI}^{PK-coordinate} + T_{update,GSI}^{FK-coordinate} = W_{update,q,GSI}^{execute} + \\
 & + t_{request}^{PK-replicaset} + \frac{P}{v_{cluster}} + W_{PK-update,GSI}^{execute} + t_{response}^{PK-replicaset} + \\
 & + t_{request}^{FK-replicaset} + \frac{P}{v_{cluster}} + W_{FK-update,GSI}^{execute} + t_{response}^{FK-replicaset},
 \end{aligned} \tag{108}$$

где:

- $W_{\text{update,q,GSI}}^{\text{execute}}$ — время ожидания запроса в очереди исполнителя;
- $T_{\text{update,GSI}}^{\text{PK-coordinate}}$ — время ожидания ответа от исполнителя с первичным ключом;
- $T_{\text{update,GSI}}^{\text{FK-coordinate}}$ — время ожидания ответа от исполнителя со вторичным ключом;
- $t_{\text{request}}^{\text{PK-replicaset}}$ и $t_{\text{response}}^{\text{PK-replicaset}}$ — времена задержки передачи запроса между координатором и исполнителем с первичным ключом по сети;
- $t_{\text{request}}^{\text{FK-replicaset}}$ и $t_{\text{response}}^{\text{FK-replicaset}}$ — времена задержки передачи запроса между координатором и исполнителем со вторичным ключом по сети;
- P — размер плана исполнения;
- v_{cluster} — скорость передачи данных между узлами СУБД;
- $W_{\text{PK-update,GSI}}^{\text{execute}}$ — время ожидания обработки запроса исполнителем с первичным ключом;
- $W_{\text{FK-update,GSI}}^{\text{execute}}$ — время ожидания обработки запроса исполнителем со вторичным ключом.

Доказательство

Запрос сначала попадает в очередь исполнителя и находится там $W_{\text{search,q,GSI}}^{\text{execute}}$ секунд.

Составленный план запроса отправляется исполнителю с первичным ключом по сети.

Все сетевые запросы сопровождается сетевой задержкой, моделируемая как гамма-распределение $\Gamma(k_{\text{cluster}}, \theta_{\text{cluster}})$.

Положим, что план запроса весит P байтов, а скорость передачи данных между узлами кластера равна v_{cluster} байтов в секунду. Тогда весь план будет передан через P/v_{cluster} секунд.

На исполнителе с первичным ключом время ожидания исполнения заявки, то есть время, проведенное в очереди в сумме с временем непосредственной обработки заявки обозначим как $W_{\text{PK-update,GSI}}^{\text{execute}}$.

На исполнителе со вторичным ключом время ожидания исполнения заявки, то есть время, проведенное в очереди в сумме с временем непосредственной обработки заявки обозначим как $W_{\text{FK-update,GSI}}^{\text{execute}}$.

Сам результат весит 16 байтов — это подтверждение записи, время его передачи мало, поэтому не учитывается.

Итого, время ожидания исполнения запроса координатора $W_{\text{update,GSI}}^{\text{coordinate}}$ рассчитывается по следующей формуле:

$$\begin{aligned}
 W_{\text{update,GSI}}^{\text{coordinate}} = & W_{\text{update,q,GSI}}^{\text{execute}} + T_{\text{update,GSI}}^{\text{PK-coordinate}} + T_{\text{update,GSI}}^{\text{FK-coordinate}} = W_{\text{update,q,GSI}}^{\text{execute}} + \\
 & + t_{\text{request}}^{\text{PK-replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{PK-update,GSI}}^{\text{execute}} + t_{\text{response}}^{\text{PK-replicaset}} + \\
 & + t_{\text{request}}^{\text{FK-replicaset}} + \frac{P}{v_{\text{cluster}}} + W_{\text{FK-update,GSI}}^{\text{execute}} + t_{\text{response}}^{\text{FK-replicaset}}, \quad (109)
 \end{aligned}$$

В правой части равенства присутствуют случайные величины, так что и левая часть является случайной величиной. $\square$

Получается, каждая заявка на обновление порождает ровно две подзадачи. Поток запросов координатора $\lambda_{\text{update,GSI}}$ распределяется равномерно на исполнителей:

$$\lambda_{\text{update,GSI}}^{\text{sub}} = \frac{2\lambda_{\text{update}}}{N}. \quad (110)$$

Время исполнения запроса на исполнителе с первичным ключом рассчитывается как худший случай поиска в B^{+} -дереве, уже несколько раз рассмотренный, в сумме с временем записи в журнал упреждающей записи. Пропустим повторные вычисления:

$$\begin{aligned}
 T_{\text{update,GSI}}^{\text{PK-execute}} = & T_{\text{WAL}} + \frac{\log_m d \log_2(2m-1)}{f_{\text{cpu}}} + \\
 & + \frac{\log_m d + 3 \cdot \frac{5.26}{2m-1}}{f_{\text{mem}}} \quad (111)
 \end{aligned}$$

Подобный расчет верен и для исполнителя со вторичным ключом:

$$T_{\text{update,GSI}}^{\text{FK-execute}} = T_{\text{WAL}} + \frac{\log_m d \log_2(2m-1)}{f_{\text{cpu}}} + \frac{\log_m d + 3 \cdot \frac{5.26}{2m-1}}{f_{\text{mem}}} \quad (112)$$

Расчеты приведенные ниже верны как для исполнителя с первичными ключами, так и для исполнителя со вторичными ключами.

Вычислим время ожидания обработки заявки $W_{\text{update,GSI}}^{\text{execute}}$ с помощью формулы Полячека-Хинчина:

$$\rho_{\text{update,GSI}}^{\text{executor}} = \lambda_{\text{update,GSI}}^{\text{sub}} T_{\text{update,GSI}}^{\text{PK-execute}}. \quad (113)$$

$$\begin{aligned} L_{\text{update,GSI}}^{\text{execute}} &= \rho_{\text{update,GSI}}^{\text{executor}} + \frac{\rho_{\text{update,GSI}}^{\text{executor}^2} + \lambda_{\text{update,GSI}}^{\text{sub}} D[T_{\text{update,GSI}}^{\text{PK-execute}}]}{2(1 - \rho_{\text{update,GSI}}^{\text{executor}})} = \\ &= \rho_{\text{update,GSI}}^{\text{executor}} + \frac{\rho_{\text{update,GSI}}^{\text{executor}^2}}{2(1 - \rho_{\text{update,GSI}}^{\text{executor}})}, \end{aligned} \quad (114)$$

и среднее время ожидания заявки в исполнителе в соответствии с законом Литтла:

$$W_{\text{PK-update,GSI}}^{\text{execute}} = \frac{L_{\text{update,GSI}}^{\text{execute}}}{\lambda_{\text{update}}} = T_{\text{update,GSI}}^{\text{PK-execute}} + \frac{\rho_{\text{update,GSI}}^{\text{executor}} T_{\text{update,GSI}}^{\text{PK-execute}}}{2(1 - \rho_{\text{update,GSI}}^{\text{executor}})}. \quad (115)$$

Время, проведенное в очереди равно времени проведенному в системе без времени обслуживания заявки, тогда:

$$W_{\text{update,q,GSI}}^{\text{execute}} = W_{\text{PK-update,GSI}}^{\text{execute}} - T_{\text{update,GSI}}^{\text{PK-execute}} = \frac{\rho_{\text{update,GSI}}^{\text{executor}} T_{\text{update,GSI}}^{\text{PK-execute}}}{2(1 - \rho_{\text{update,GSI}}^{\text{executor}})}. \quad (116)$$

Рассчитаем время работы координатора. Только времена сетевой задержки — случайные величины, остальные — скалярные, так что, согласно свойствам гамма-распределения, время работы координатора — случайная величина, имеющая сдвинутое гамма-распределение. Случайную часть $T_{\text{update,GSI}}^{\text{PK-coordinate}}$ обозначим Y , а детерминированную — $C^{\text{coordinate}}$.

$$C^{\text{coordinate}} = W_{\text{PK-update,GSI}}^{\text{execute}} + W_{\text{FK-update,GSI}}^{\text{execute}} + \frac{P}{v_{\text{cluster}}}, \quad (117)$$

$$Y = T_{\text{update,GSI}}^{\text{PK-coordinate}} - C^{\text{coordinate}} \sim \Gamma(4k_{\text{cluster}}, \theta_{\text{cluster}}). \quad (118)$$

Следовательно функция распределения равна:

$$F_Y(t) = P(Y \leq t) = \frac{\gamma(4k_{\text{cluster}}, t/\theta_{\text{cluster}})}{\Gamma(4k_{\text{cluster}})}. \quad (119)$$

Времена сетевых задержек во времени ожидания пользователя $T_{\text{update,GSI}}^{\text{user}}$ обозначим X , тогда:

$$X = t_{\text{request}}^{\text{user}} + t_{\text{response}}^{\text{user}} \sim \Gamma(2k_{\text{user}}, \theta_{\text{user}}), \quad (120)$$

следовательно:

$$\begin{aligned} M[T_{\text{update,GSI}}^{\text{user}}] &= M[X] + M[W_{\text{update,GSI}}^{\text{coordinate}}] = \\ &= k_{\text{user}} \theta_{\text{user}} + M[T_{\text{update,GSI}}^{\text{PK-coordinate}}] + M[T_{\text{update,GSI}}^{\text{FK-coordinate}}], \end{aligned} \quad (121)$$

$$\begin{aligned} D[T_{\text{update,GSI}}^{\text{user}}] &= D[Y] + D[W_{\text{update,GSI}}^{\text{coordinate}}] = \\ &= k_{\text{user}} \theta_{\text{user}}^2 + 2D[T_{\text{update,GSI}}^{\text{PK-coordinate}}]. \end{aligned} \quad (122)$$

3.8 Расчет параметров эффективности

Максимальное количество запросов в секунду достигается при максимальной загрузке системы. Так как мы договорились, что по факту работа на координаторе не учитывается в модели, то на него можно подать бесконечную нагрузку. Тогда единственным ограничивающим фактором системы является время обработки заявки исполнителем $T_{\text{update,GSI}}^{\text{PK-execute}}$.

Для устойчивости системы, загрузка системы $\rho_{\text{update,GSI}}^{\text{executor}}$ должна не превышать единицу. По определению, загрузка системы рассчитывается по формуле (113), значит максимальная нагрузка системы рассчитывается по следующей формуле:

$$\lambda_{\text{update,GSI}}^{\text{sub,max}} = \frac{1}{T_{\text{update,GSI}}^{\text{PK-execute}}}, \quad (123)$$

а по формуле (110), верно, что:

$$\lambda_{\text{update,GSI}}^{\max} = \lambda_{\text{update,GSI}}^{\text{sub,max}} N = \frac{N}{T_{\text{update,GSI}}^{\text{PK-execute}}}. \quad (124)$$

Найдем вероятность того, что время ожидания пользователем завершения операции обновления $T_{\text{update,GSI}}^{\text{user}}$ превысит заданный лимит T_{timeout} , то есть вычислим $P(T_{\text{update,GSI}}^{\text{user}} \geq T_{\text{timeout}})$.

Время ожидания пользователя складывается из детерминированной и случайной частей:

$$T_{\text{update,GSI}}^{\text{user}} = W_{\text{update,q,GSI}}^{\text{execute}} + C^{\text{coordinate}} + Y + X, \quad (125)$$

где

- $X \sim \text{Gamma}(2k_{\text{user}}, \theta_{\text{user}})$ – суммарная задержка сети между пользователем и координатором (запрос + ответ);
- $Y \sim \text{Gamma}(4k_{\text{cluster}}, \theta_{\text{cluster}})$ – суммарная задержка сети между координатором и исполнителем;
- детерминированная составляющая $C^{\text{user}} = W_{\text{update,q,GSI}}^{\text{execute}} + C^{\text{coordinate}}$.

Результат подтверждения записи пренебрежимо мал, поэтому не учитывается.

Определим $\tau = T_{\text{timeout}} - C^{\text{user}}$. При $\tau > 0$ воспользуемся формулой свёртки для суммы двух независимых случайных величин. Обозначим $X = X$, $Y = Y$. Плотность X известна:

$$f_{X(t)} = \frac{t^{2k_{\text{user}}-1} e^{-t/\theta_{\text{user}}}}{\theta_{\text{user}}^{2k_{\text{user}}} \Gamma(2k_{\text{user}})}, t \geq 0. \quad (126)$$

Функция распределения Y выражается через регуляризованную нижнюю неполную гамма-функцию:

$$F_{Y(y)} = P(Y \leq y) = \frac{\gamma(4k_{\text{cluster}}, y/\theta_{\text{cluster}})}{\Gamma(4k_{\text{cluster}})}. \quad (127)$$

Вероятность таймаута:

$$\begin{aligned}
P(T_{\text{update,GSI}}^{\text{user}} \geq T_{\text{timeout}}) &= P(X + Y \geq \tau) = \\
&= \int_0^\tau f_{X(t)} (1 - F_{Y(\tau-t)}) dt + \int_\tau^\infty f_{X(t)} dt.
\end{aligned} \tag{128}$$

Второе слагаемое — вероятность того, что одна лишь пользовательская задержка уже превышает τ , и равно $1 - P(2k_{\text{user}}, \tau/\theta_{\text{user}})$, где $P(a, x) = \gamma(a, x)/\Gamma(a)$. Первое слагаемое учитывает случаи, когда $X = t < \tau$, но Y компенсирует оставшееся время.

Подставляя явные выражения, получаем окончательную формулу:

$$\begin{aligned}
P(T_{\text{update,GSI}}^{\text{user}} \geq T_{\text{timeout}}) &= \\
&= \int_0^\tau \frac{t^{2k_{\text{user}}-1} e^{-t/\theta_{\text{user}}}}{\theta_{\text{user}}^{2k_{\text{user}}} \Gamma(2k_{\text{user}})} \left(1 - \frac{\gamma(4k_{\text{cluster}}, (\tau-t)/\theta_{\text{cluster}})}{\Gamma(4k_{\text{cluster}})} \right) dt + \\
&\quad + 1 - \frac{\gamma(2k_{\text{user}}, \tau/\theta_{\text{user}})}{\Gamma(2k_{\text{user}})}.
\end{aligned} \tag{129}$$

Все величины, входящие в формулу, определены в предыдущих разделах. Интеграл вычисляется численно методом Симпсона, так как замкнутая форма для свертки гамма-распределений с разными параметрами масштаба отсутствует. В частном случае $\theta_{\text{user}} = \theta_{\text{cluster}}$ сумма $X + Y$ имеет гамма-распределение $\Gamma(2k_{\text{user}} + 4k_{\text{cluster}}, \theta_{\text{user}})$, и вероятность можно вычислить аналитически через регуляризованную гамма-функцию.

Среднее время обслуживания заявки равняется $M[T_{\text{update,GSI}}^{\text{user}}]$.

Среднее время ожидания заявки в очереди является суммарным временем нахождения заявки во всех очередях, то есть рассчитывается по формуле (130):

$$W_{\text{update,q,GSI}}^{\text{total}} = 3W_{\text{update,q,GSI}}^{\text{execute}}, \tag{130}$$

так как сначала заявки ожидает в очереди координатора за $W_{\text{update,q,GSI}}^{\text{execute}}$, потом еще столько же в исполнителе.

3.9 Результат расчетов и сравнение

В данной главе сведены воедино результаты анализа ЛВИ и ГВИ в СУБД Picodata, полученные в пунктах 3.3, 3.4, 3.5 и 3.7. Сравнение проводится по трем направлениям: качественная оценка архитектурных свойств, количественное сопоставление формул показателей эффективности и анализ предельных режимов работы.

3.9.1 Качественное сравнение

Качественные различия двух индексных структур определяются способом размещения данных индекса и порождаемыми алгоритмами координации.

Поиск по вторичным ключам:

- в ЛВИ индекс сегментирован вместе с данными, поэтому для поиска по вторичному ключу координатор вынужден опросить все наборы реплик. Число сетевых запросов линейно зависит от размера кластера: $NR_{\text{search}}^{\text{LSI}} = 2N + 2$, согласно формуле (3). Это ограничивает горизонтальное масштабирование при поисковых нагрузках;
- в ГВИ индекс сегментирован по самому вторичному ключу, благодаря чему координатор направляет запрос единственному исполнителю, владеющему нужной частью индекса. Число сетевых запросов лежит в диапазоне от 6 до $2k + 4$, где k — количество наборов реплик, содержащих искомые записи, согласно формуле (39). При высокой кардинальности вторичного ключа ($K \rightarrow D$) k мало, и сетевых взаимодействий становится значительно меньше, чем в ЛВИ.

Обновление индекса:

- в ЛВИ обновление затрагивает только тот набор реплик, которому принадлежит модифицируемая запись. Число сетевых запросов равно 4.
- в ГВИ обновление требует двухэтапной фиксации: сначала обновляется таблица и первичный индекс на одном наборе реплик, затем — глобальный вторичный индекс на другом. Возникают две подзадачи, дважды выполняется запись в журнал упреждающей

записи, а число сетевых запросов равно 6, но полное время операции возрастает.

Важно отметить, что сейчас ввиду отсутствия распределенных транзакций в СУБД Picodata, строгая консистенция невозможна при обновлении ГВИ, в отличие от ЛВИ. С введением такого механизма консистенция будет достигаться за счет дольшего времени обработки заявки.

3.9.2 Количественное сравнение

Количественное сопоставление проводится на основе итоговых выражений для показателей эффективности СМО из четырех предыдущих разделов. Сравниваются:

- максимальная интенсивность входного потока $\lambda^{\max}$, при которой система остается устойчивой;
- среднее время ожидания пользователя $M[T^{\text{user}}]$;
- среднее суммарное время в очередях W_q^{total} ;
- вероятность таймаута $P(T^{\text{user}} \geq T_{\text{timeout}})$.

3.9.2.1 Максимальная пропускная способность

Устойчивость каждой конфигурации определяется загрузкой исполнителей. Ниже приведены максимальные интенсивности запросов, которые способен выдержать кластер из N наборов реплик.

Таблица 2 — Максимальные интенсивности запросов, при которых сохраняется устойчивость

Конфигурация	ЛВИ	ГВИ
Поиск	$\lambda_{\text{search,LSI}}^{\max} = \frac{1}{T_{\text{search,LSI}}^{\text{execute}}}$	$\lambda_{\text{search,GSI}}^{\max} = \frac{N}{kT_{\text{search,GSI}}^{\text{execute}}}$
Обновление	$\lambda_{\text{update,LSI}}^{\max} = \frac{N}{T_{\text{update,LSI}}^{\text{execute}}}$	$\lambda_{\text{update,GSI}}^{\max} = \frac{N}{2T_{\text{update,GSI}}^{\text{PK-execute}}}$

Сравним пропускную способность поиска. Отношение максимальных интенсивностей:

$$\frac{\lambda_{\text{search,GSI}}^{\max}}{\lambda_{\text{search,LSI}}^{\max}} = \left(\frac{N}{k} \right). \quad (131)$$

Таким образом, ГВИ не уступает ЛВИ даже при самом худшем варианте — когда $k = N$, а в остальных случаях даже выигрывает.

Пропускная способность обновления в ГВИ примерно вдвое ниже, чем в ЛВИ, из-за записи в два исполнителя :

$$\lambda_{\text{update,GSI}}^{\max} = \left(\frac{1}{2} \right) \lambda_{\text{update,LSI}}^{\max}. \quad (132)$$

3.9.2.2 Среднее время ожидания пользователя

Среднее время $M[T^{\text{user}}]$ складывается из сетевых задержек, времени работы координатора и времени ожидания в очередях. Сравним на качественном уровне:

- время поиска в ЛВИ включает ожидание ответа от всех N исполнителей и максимум их времен обслуживания. С ростом N максимум растет как $O(\log N)$ (для распределения с легким хвостом), а детерминированная часть пропорциональна $\frac{1}{Nf_k}$ по числу найденных записей на узел;
- в ГВИ поиск ожидает ответа от k исполнителей, причем на координаторе дополнительно ожидается работа исполнителя со вторичным ключом индекса. При малых k среднее время поиска в ГВИ существенно ниже, при больших k оно приближается к времени ЛВИ из-за двойного посещения очередей.

Обновление в ЛВИ всегда затрагивает только один набор реплик, поэтому его среднее время минимально. В ГВИ суммарное время состоит из двух последовательных взаимодействий с разными наборами реплик, что дает приблизительно удвоенное время по сравнению с ЛВИ при одинаковых интенсивностях, так как именно сетевые задержки становятся узким горлышком.

3.9.2.3 Среднее время в очередях

Суммарное время нахождения заявки во всех очередях характеризует внутренние задержки системы:

- поиск ЛВИ: $W_{\text{update},q,\text{LSI}}^{\text{total}} = 2W_{\text{search},q,\text{LSI}}^{\text{execute}}$;
- поиск ГВИ: $W_{\text{search},q,\text{GSI}}^{\text{total}} = 3W_{\text{search},q,\text{GSI}}^{\text{execute}}$;
- обновление ЛВИ: $W_{\text{update},q,\text{LSI}}^{\text{total}} = 2W_{\text{update},q,\text{LSI}}^{\text{execute}}$;
- обновление ГВИ: $W_{\text{update},q,\text{GSI}}^{\text{total}} = 3W_{\text{update},q,\text{GSI}}^{\text{execute}}$.

Большее число этапов очередей в ГВИ приводит к большему накоплению задержек при высоких нагрузках.

3.9.2.4 Вероятность таймаута

Вероятность превышения лимита T_{timeout} выражается интегралами сверток:

- в ЛВИ случайная составляющая времени пользователя складывается из задержек пользователь–кластер и кластер–один исполнитель, поскольку координатор ждет максимум, но сетевых обменов с каждым исполнителем всего два — дисперсия максимума N одинаковых величин меньше дисперсии суммы дополнительных этапов ГВИ;
- в ГВИ случайная часть включает задержки пользователь–координатор, координатор–владелец индекса и максимум k обменов с исполнителями — суммирование трех независимых компонент увеличивает дисперсию, что при одинаковом среднем может повышать вероятность таймаута.

3.9.3 Выводы и область предпочтительности

Проведенный анализ позволяет сформулировать условия, при которых глобальный вторичный индекс предпочтительнее локального, и наоборот.

ГВИ дает выигрыш для поиска при следующих условиях:

- высокая кардинальность вторичного ключа (K близка к D), так что k мало (в идеале $k \approx 1$) — в этом случае время поиска и число сетевых взаимодействий значительно снижаются;
- кластер содержит много наборов реплик (N велико) — ЛВИ опрашивает все N узлов, тогда как ГВИ — лишь малую долю;
- сеть между узлами нестабильна или обладает высокой латентностью, тогда сокращение числа сетевых обменов критически важно.

ЛВИ сохраняет преимущество в следующих ситуациях:

- кардинальность вторичного ключа мала ($K \ll D$), и k приближается к N . В этом случае выигрыш ГВИ нивелируется;
- доминирует нагрузка на обновление данных — ЛВИ обновляется локально и быстрее, а ГВИ требует двухэтапной записи с дополнительными сетевыми задержками;
- желательна максимальная пропускная способность системы при смешанной нагрузке с преобладанием обновлений — ЛВИ обеспечивает более высокую интенсивность обновлений.

Таким образом, выбор индексной структуры не является универсальным и должен опираться на ожидаемый профиль нагрузки, объем данных и топологию кластера. Приведенные в главах 3.3–3.7 математические модели и полученные выше формулы позволяют выполнить численный расчет показателей эффективности для конкретных значений параметров и принять обоснованное архитектурное решение.

4 Модель функционирования плагина распределенного индекса

4.1 Контекстная диаграмма

4.2 Диаграмма потоков данных

4.2.1 Функциональная декомпозиция

5 Архитектура плагина распределенного индекса

5.1 Архитектура плагина

5.1.1 Диаграмма развертывания

5.1.2 Представление данных

5.1.3 Описание алгоритмов

6 Описание способов определения показателей качества ПО

6.1 Показатели качества

6.2 Способы определения показателей качества

7 Программа и методики испытаний ПО

7.1 Модель функционирования системы тестирования

7.1.1 Контекстная диаграмма

7.1.2 Диаграмма потоков данных

7.1.2.1 Функциональная декомпозиция

7.2 Архитектура системы тестирования индексных структур

7.2.1 Общие сведения

7.2.2 Структурные представления

7.2.3 Архитектура решения

7.2.3.1 Основные положения архитектуры

7.2.3.2 Диаграмма развертывания

7.2.3.3 Представление данных

7.3 Сравнение полученных результатов с математическими моделями

ЗАКЛЮЧЕНИЕ

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Википедия. В+-дерево [Электронный ресурс]. 2026. URL: <https://ru.wikipedia.org/wiki/B%E2%81%BA-%D0%B4%D0%B5%D1%80%D0%B5%D0%B2%D0%BE>.
2. Википедия. В*-дерево [Электронный ресурс]. 2026. URL: https://ru.wikipedia.org/wiki/B*-%D0%B4%D0%B5%D1%80%D0%B5%D0%B2%D0%BE.
3. Tarantool Developers. Tarantool source code: bps_tree.h [Электронный ресурс]. 2025. URL: https://github.com/tarantool/tarantool/blob/4e27591f685e9c695853a0165d4081148d12e315/src/lib/salad/bps_tree.h (дата обращения: 11.04.2026).
4. Бабин О. Как написать свой индекс в Tarantool [Электронный ресурс]. 2020. URL: <https://habr.com/ru/companies/vk/articles/505880/>.
5. Портал документации Picodata [Электронный ресурс]. ООО "Пикодата", 2026. URL: <https://docs.picodata.io/picodata/stable/> (дата обращения: 02.03.2026).
6. Kleppmann M. Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems. Sebastopol, CA: O'Reilly Media, 2017.
7. Chen P. P.-S. The entity-relationship model—toward a unified view of data // ACM Transactions on Database Systems. Association for Computing Machinery (ACM), 1976. Т. 1, № 1. Сс. 9–36.
8. Вентцель Е. С. Исследование операций: задачи, принципы, методология. 2-е изд. "Наука" Главная редакция физико-математической литературы, 1988.
9. Розенберг В. Я., Прохоров А. И. Что такое теория массового обслуживания. 2-е изд. Москва: Советское радио, 1965. С. 256.
10. Shortle J. F. и др. Fundamentals of Queueing Theory. 5-е изд. Hoboken, NJ: Wiley, 2018.
11. Liu Y., Li J., Gu N. Modeling Internet Link Delay Based on Measurement // 2009 International Conference on Computational Science and Engineering. Vancouver, BC, Canada: IEEE, 2009. Т. 4. Сс. 874–879.

12. Valadão E. D. и др. Caracterização de tempos de ida-e-volta na Internet // Revista de Informática Teórica e Aplicada. Porto Alegre, Brazil: UFRGS, 2012. Т. 19, № 2. Сс. 4–20.
13. France R. и др. The UML as a formal modeling notation // Computer Standards & Interfaces. Elsevier BV, 1998. Т. 19, № 7. Сс. 325–334.
14. Кибзун А. И., Горяинова Е. Р., Наумов А. В. Теория вероятностей и математическая статистика. Базовый курс с примерами и задачами. 3-е изд. Москва: Физматлит, 2011.
15. Ross S. M. A First Course in Probability. 10-е изд. Pearson, 2019.
16. Leung C. H. C. Approximate storage utilisation of B-trees: A simple derivation and generalisations // Information Processing Letters. Elsevier, 1984. Т. 19, № 4. Сс. 199–201.